

Les arbres de décision

Théorie, démonstrations, critères d'impureté
et interprétation des résultats

5 juin 2026

Table des matières

1	Introduction	1
2	Formulation mathématique du modèle	1
3	Construction récursive (algorithme glouton)	1
4	Critères d'impureté	2
4.1	Classification	2
4.1.1	Indice de Gini	2
4.1.2	Moyenne pondérée et gain	2
4.1.3	Entropie de Shannon	3
4.2	Régression	3
5	Justification théorique et compromis biais–variance	4
5.1	Un estimateur non paramétrique	4
5.2	Compromis biais–variance	4
6	Élagage (Pruning)	4
6.1	Élagage par coût-complexité	4
7	Interprétation des résultats	5
7.1	Règles de décision	5
7.2	Importance des variables	5
8	Limites théoriques	5
9	Conclusion	5

1 Introduction

Les **arbres de décision** sont des méthodes d'apprentissage supervisé, utilisées en *classification* comme en *régression*. Leur principe : **partitionner récursivement** l'espace des variables explicatives en régions, puis prédire une valeur constante dans chaque région. Le modèle obtenu se lit comme une cascade de règles logiques « si . . . alors . . . », ce qui en fait l'un des modèles les plus **interprétables**.

Intuition

Imaginez trier des fruits : « le diamètre est-il > 6 cm ? » puis « la couleur est-elle rouge ? ». Chaque question coupe la population en deux. Un arbre apprend automatiquement *quelles questions poser* et *dans quel ordre* pour séparer au mieux les classes.

2 Formulation mathématique du modèle

Soit l'échantillon d'apprentissage $\mathcal{D} = \{(\mathbf{X}_i, Y_i)\}_{i=1}^n$, avec $\mathbf{X}_i \in \mathbb{R}^p$ (variables explicatives) et Y_i la cible. Un arbre définit une **partition** de $\mathbb{R}^p$ en M régions disjointes $\{R_1, \dots, R_M\}$ (les *feuilles*), et une fonction prédictive **constante par morceaux** :

$$f(\mathbf{X}) = \sum_{m=1}^M c_m \mathbb{1}_{\{\mathbf{X} \in R_m\}},$$

où $\mathbb{1}_{\{\cdot\}}$ vaut 1 si la condition est vraie, 0 sinon, et c_m est la valeur prédite dans la région R_m (une classe en classification, un réel en régression).

Intuition

La somme contient un seul terme non nul : celui de la région où tombe $\mathbf{X}$. Prédire revient à « descendre » l'arbre jusqu'à une feuille et renvoyer sa constante.

3 Construction récursive (algorithme glouton)

À chaque nœud, on cherche une **coupure** (*split*) binaire de la forme

$$X_j \leq s \quad \text{ou} \quad X_j > s, \quad j \in \{1, \dots, p\}, \quad s \in \mathbb{R},$$

qui sépare les observations du nœud en deux sous-nœuds (gauche t_g , droite t_d). On choisit le couple (j, s) qui **minimise une fonction d'impureté** (définie ci-dessous).

L'algorithme, en résumé

1. Au nœud courant, pour *chaque* variable j et *chaque* seuil candidat s , calculer l'impureté après coupure.
2. Retenir le split (j^*, s^*) qui maximise la **diminution d'impureté**.
3. Créer les deux sous-nœuds et **recommencer** récursivement sur chacun.
4. S'arrêter selon un critère (nœud pur, profondeur max, effectif minimal...).

Pourquoi « glouton » ?

Trouver l'arbre globalement optimal est un problème NP-difficile (trop de partitions possibles). On adopte donc une stratégie **gloutonne** : à chaque étape, on prend la *meilleure coupure locale* sans se soucier des suivantes. Ce n'est pas garanti optimal globalement, mais c'est rapide et efficace en pratique.

4 Critères d'impureté

4.1 Classification

Soit K le nombre de classes et p_k la proportion d'observations de la classe k dans un nœud t (donc $\sum_k p_k = 1$). Une mesure d'impureté doit valoir 0 quand le nœud est **pur** (une seule classe) et être **maximale** quand les classes sont équiréparties.

4.1.1 Indice de Gini

Définition 4.1 (Impureté de Gini).

$$G(t) = \sum_{k=1}^K p_k(1 - p_k) = 1 - \sum_{k=1}^K p_k^2.$$

L'égalité des deux formes : $\sum_k p_k(1 - p_k) = \sum_k p_k - \sum_k p_k^2 = 1 - \sum_k p_k^2$ (car $\sum_k p_k = 1$).

Que mesure le Gini ?

$G(t)$ est la **probabilité de se tromper** si l'on étiquetait une observation au hasard selon la distribution des classes du nœud. Si le nœud est pur, on ne se trompe jamais ($G = 0$). Si les classes sont équiréparties, on se trompe souvent (G maximal). Pour $K = 2$: $G = 2p(1 - p)$, maximal = 0,5 en $p = 0,5$, nul en $p \in \{0, 1\}$.

4.1.2 Moyenne pondérée et gain

Après une coupure, le nœud parent t (effectif n) se sépare en t_g (effectif n_g) et t_d (effectif n_d). L'impureté globale après coupure est la **moyenne pondérée par les effectifs** :

$$G_{\text{pond}} = \frac{n_g}{n} G(t_g) + \frac{n_d}{n} G(t_d).$$

Pourquoi pondérer ?

Sans pondération, un minuscule sous-nœud parfaitement pur ferait croire à une excellente coupure. En pondérant par la taille, un gros sous-nœud compte davantage : on évite qu'un détail numériquement insignifiant ne fausse le choix.

La coupure optimale **minimise** G_{pond} , ce qui équivaut à **maximiser la diminution d'impureté** :

$$\Delta G = G(t) - G_{\text{pond}}.$$

Exemple 4.1 (Calcul d'un split, pas à pas). Nœud parent : 10 observations, 6 positives et 4 négatives.

$$G(t) = 1 - \left[(0,6)^2 + (0,4)^2 \right] = 1 - 0,52 = 0,48.$$

Une coupure donne : $t_g = \{4 \text{ pos}, 0 \text{ nég}\}$ (pur, $G(t_g) = 0$) et $t_d = \{2 \text{ pos}, 4 \text{ nég}\}$:

$$G(t_d) = 1 - \left[\left(\frac{2}{6}\right)^2 + \left(\frac{4}{6}\right)^2 \right] = 1 - (0,111 + 0,444) = 0,444.$$

Moyenne pondérée :

$$G_{\text{pond}} = \frac{4}{10} \cdot 0 + \frac{6}{10} \cdot 0,444 = 0,267, \quad \Delta G = 0,48 - 0,267 = 0,213 > 0.$$

Cette coupure améliore la pureté : elle est candidate. On la compare à toutes les autres et on garde celle de plus grand ΔG .

4.1.3 Entropie de Shannon

Définition 4.2 (Entropie).

$$H(t) = - \sum_{k=1}^K p_k \log(p_k).$$

Que mesure l'entropie ?

C'est la quantité moyenne d'**information** (en bits si $\log_2$) nécessaire pour identifier la classe d'une observation, autrement dit le « désordre ». Pure $\Rightarrow H = 0$ (aucune incertitude) ; équirépartie $\Rightarrow H$ maximal ($= \log K$).

Le **gain d'information** d'une coupure est

$$\Delta H = H(t) - \left(\frac{n_g}{n} H(t_g) + \frac{n_d}{n} H(t_d) \right),$$

et l'on retient la coupure qui le maximise.

Gini ou entropie ?

Les deux donnent des arbres très semblables en pratique. Le Gini est légèrement moins coûteux (pas de logarithme) et c'est le défaut de `scikit-learn`. L'entropie a une interprétation théorique en information ; elle pénalise un peu plus fortement les nœuds très impurs.

4.2 Régression

En régression, on remplace l'impureté par la **somme des carrés des résidus** dans le nœud :

$$\text{RSS}(t) = \sum_{i \in t} (Y_i - c)^2.$$

Proposition 4.1. *La constante c minimisant $\text{RSS}(t)$ est la **moyenne empirique des cibles du nœud** :*

$$c_t = \frac{1}{|t|} \sum_{i \in t} Y_i.$$

Démonstration. On dérive $\text{RSS}(t)$ par rapport à c :

$$\frac{d}{dc} \sum_{i \in t} (Y_i - c)^2 = \sum_{i \in t} 2(Y_i - c)(-1) = -2 \sum_{i \in t} (Y_i - c).$$

L'annulation donne $\sum_{i \in t} (Y_i - c) = 0$, soit $\sum_{i \in t} Y_i = |t| c$, d'où $c = \frac{1}{|t|} \sum_{i \in t} Y_i$. La dérivée seconde vaut $2|t| > 0$: c'est bien un minimum. $\square$

Intuition

À l'optimum, $\text{RSS}(t) = \sum_{i \in t} (Y_i - \bar{Y}_t)^2 = |t| \cdot \text{Var}(Y | t)$: minimiser la RSS pondérée des deux sous-nœuds revient à **minimiser la variance intra-nœud**. L'arbre cherche des coupures qui rendent les cibles homogènes dans chaque feuille.

5 Justification théorique et compromis biais–variance

5.1 Un estimateur non paramétrique

Les arbres sont des estimateurs **constants par morceaux**. En augmentant la profondeur, on multiplie les régions et l'on peut approximer *toute* fonction mesurable, au prix d'une variance croissante. C'est un modèle **non paramétrique** : sa complexité croît avec les données.

5.2 Compromis biais–variance

- **Arbre profond** : biais faible (colle aux données), variance élevée (sur-apprentissage).
- **Arbre peu profond** : biais élevé (trop grossier), variance faible.

Contrôler la profondeur (ou élaguer) revient à régler ce compromis.

6 Élagage (Pruning)

Un arbre laissé libre sur-apprend. On le contrôle de deux manières : par **pré-élagage** (critères d'arrêt : profondeur maximale, effectif minimal par feuille, gain minimal) ou par **post-élagage** (laisser pousser, puis couper).

6.1 Élagage par coût-complexité

On pénalise la taille de l'arbre. Pour un arbre T de $|T|$ feuilles et d'erreur $R(T)$ (impureté/RSS totale), on définit le **coût-complexité** :

$$R_\alpha(T) = R(T) + \alpha |T|, \quad \alpha \geq 0. \quad (1)$$

Intuition

α est le « prix » d'une feuille supplémentaire. Si $\alpha = 0$, on garde l'arbre complet (erreur minimale, gros). Plus α augmente, plus on coupe de feuilles : l'arbre rétrécit. C'est l'exact analogue du paramètre λ de la régularisation Ridge/Lasso, mais appliqué à la *structure* de l'arbre.

Théorème 6.1 (Sous-arbres optimaux emboîtés). *Pour toute valeur de α , il existe un **unique plus petit** sous-arbre T_α minimisant $R_\alpha(T)$. Quand α croît de 0 à $+\infty$, ces sous-arbres optimaux forment une suite finie **emboîtée** $T_0 \supset T_1 \supset \dots \supset \{\text{racine}\}$.*

Le « maillon faible » (weakest-link pruning)

On obtient cette suite en coupant à chaque étape le nœud interne t dont le « lien » est le plus faible, mesuré par

$$g(t) = \frac{R(t) - R(T_t)}{|T_t| - 1},$$

où T_t est le sous-arbre enraciné en t . Le nœud de plus petit $g(t)$ apporte le moins de gain par feuille : on le transforme en feuille en premier. La bonne valeur de α (et donc le bon arbre dans la suite) se choisit par **validation croisée**.

7 Interprétation des résultats

7.1 Règles de décision

Chaque chemin de la racine à une feuille se lit comme une **règle logique** (conjonction de conditions) :

$$(X_1 \leq s_1) \wedge (X_2 > s_2) \Rightarrow \text{Classe } k.$$

C'est la grande force des arbres : un humain peut suivre et vérifier le raisonnement.

7.2 Importance des variables

On mesure la contribution globale d'une variable X_j en sommant les diminutions d'impureté de *tous* les nœuds qui coupent sur X_j :

$$\text{Imp}(X_j) = \sum_{t \in T_j} \frac{n_t}{n} \Delta I(t),$$

où T_j est l'ensemble des nœuds coupant sur X_j , $\Delta I(t)$ la diminution d'impureté au nœud t , et $\frac{n_t}{n}$ la fraction d'observations qui l'atteignent. On normalise généralement pour que les importances somment à 1.

Intuition

Une variable qui produit de gros ΔI près de la racine (où n_t est grand) reçoit une forte importance. Attention : cette mesure favorise les variables à nombreuses modalités et peut être trompeuse en présence de variables corrélées.

8 Limites théoriques

- **Instabilité** : une petite variation des données peut changer complètement l'arbre (variance élevée). C'est précisément ce que corrigent le *bagging* et le *Random Forest* (moyenner beaucoup d'arbres).
- **Coupures axis-parallèles** : chaque split ne porte que sur une variable à la fois ; les frontières sont des « escaliers » et capturent mal les relations obliques.
- **Optimisation locale** : l'algorithme glouton ne garantit pas l'arbre globalement optimal.
- **Sur-apprentissage** : sans contrôle de complexité (profondeur, élagage), un arbre mémorise le bruit.

9 Conclusion

À retenir

Les arbres de décision offrent un excellent compromis entre **performance** et **interprétabilité** :

- ils partitionnent l'espace par coupures binaires, choisies par minimisation d'une impureté (Gini / entropie en classification, RSS en régression) ;
- la valeur d'une feuille est la classe majoritaire ou la moyenne des cibles ;
- leur complexité se contrôle par profondeur, effectifs minimaux ou élagage coût-complexité $R_\alpha(T) = R(T) + \alpha|T|$;
- leur instabilité est le point de départ des méthodes d'ensemble (bagging, Random Forest, boosting).