

# L'analyse en composantes principales (ACP / PCA)

Variance maximale, erreur minimale, lien SVD  
et démonstrations

---

5 juin 2026

---

## Table des matières

|           |                                                                 |          |
|-----------|-----------------------------------------------------------------|----------|
| <b>1</b>  | <b>Introduction</b>                                             | <b>1</b> |
| <b>2</b>  | <b>Cadre mathématique</b>                                       | <b>1</b> |
| 2.1       | Centrage . . . . .                                              | 1        |
| 2.2       | Matrice de covariance . . . . .                                 | 1        |
| <b>3</b>  | <b>Le problème fondamental : deux formulations équivalentes</b> | <b>2</b> |
| 3.1       | Formulation « variance maximale » . . . . .                     | 2        |
| 3.2       | Formulation « erreur de reconstruction minimale » . . . . .     | 2        |
| <b>4</b>  | <b>Cas d'une dimension : pourquoi les vecteurs propres ?</b>    | <b>2</b> |
| <b>5</b>  | <b>Résolution en dimension <math>k</math></b>                   | <b>3</b> |
| 5.1       | Variance expliquée . . . . .                                    | 3        |
| <b>6</b>  | <b>Projection, reconstruction et erreur</b>                     | <b>3</b> |
| <b>7</b>  | <b>Lien avec la SVD</b>                                         | <b>3</b> |
| <b>8</b>  | <b>Exemple numérique complet</b>                                | <b>4</b> |
| <b>9</b>  | <b>Choix du nombre de composantes</b>                           | <b>4</b> |
| <b>10</b> | <b>Limites et extensions</b>                                    | <b>5</b> |
| <b>11</b> | <b>Synthèse</b>                                                 | <b>5</b> |

---

## 1 Introduction

L'analyse en composantes principales (ACP, ou PCA) est une méthode de **réduction de dimension linéaire** : représenter des données de grande dimension dans un espace plus petit en conservant un **maximum d'information**. Ici, l'information est mesurée par la **variance** : l'ACP cherche les directions dans lesquelles les données varient le plus.

### Intuition

Si une direction porte beaucoup de variance, les points y sont bien « étalés » : elle distingue les observations, donc elle est informative. Une direction de variance quasi nulle (tous les points s'y projettent au même endroit) n'apprend rien : on peut la supprimer sans grande perte.

## 2 Cadre mathématique

On a  $N$  observations  $\mathbf{x}_i \in \mathbb{R}^d$ , empilées en une matrice de données

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_N^\top \end{pmatrix} \in \mathbb{R}^{N \times d}.$$

### 2.1 Centrage

La moyenne empirique est  $\mu = \frac{1}{N} \sum_i \mathbf{x}_i$ . Les données centrées sont  $\tilde{\mathbf{x}}_i = \mathbf{x}_i - \mu$ , soit  $\tilde{\mathbf{X}} = \mathbf{X} - \mathbf{1}\mu^\top$ .

#### Pourquoi centrer ?

L'ACP décrit la **variabilité autour du barycentre**. Sans centrage, la première composante capterait surtout la *position moyenne* du nuage (un vecteur pointant vers  $\mu$ ), pas sa forme. Le centrage place l'origine au centre du nuage.

### 2.2 Matrice de covariance

$$\Sigma = \frac{1}{N} \tilde{\mathbf{X}}^\top \tilde{\mathbf{X}} \in \mathbb{R}^{d \times d}.$$

**Propriétés :**  $\Sigma$  est symétrique, semi-définie positive, donc diagonalisable dans une base orthonormée (théorème spectral) avec des valeurs propres réelles  $\geq 0$ .

## 3 Le problème fondamental : deux formulations équivalentes

### 3.1 Formulation « variance maximale »

On cherche un sous-espace de dimension  $k$  qui maximise la variance projetée. Soit  $\mathbf{U} \in \mathbb{R}^{d \times k}$  avec colonnes orthonormées ( $\mathbf{U}^\top \mathbf{U} = \mathbf{I}_k$ ). Le problème PCA s'écrit

$$\max_{\mathbf{U}^\top \mathbf{U} = \mathbf{I}_k} \text{Tr}(\mathbf{U}^\top \Sigma \mathbf{U}). \quad (1)$$

### 3.2 Formulation « erreur de reconstruction minimale »

On cherche à approximer chaque point par sa projection sur le sous-espace, en minimisant l'erreur quadratique :

$$\min_{\mathbf{U}^\top \mathbf{U} = \mathbf{I}_k} \sum_{i=1}^N \left\| \tilde{\mathbf{x}}_i - \mathbf{U} \mathbf{U}^\top \tilde{\mathbf{x}}_i \right\|^2. \quad (2)$$

**Proposition 3.1** (Équivalence des deux formulations). *Maximiser la variance projetée (1) équivaut à minimiser l'erreur de reconstruction (2).*

*Démonstration.* Prenons le cas  $k = 1$  (direction unitaire  $\mathbf{u}$ ). La projection est  $z_i = \mathbf{u}^\top \tilde{\mathbf{x}}_i$  et la reconstruction  $z_i \mathbf{u}$ . Comme la projection orthogonale et le résidu sont perpendiculaires (Pythagore) :

$$\|\tilde{\mathbf{x}}_i - z_i \mathbf{u}\|^2 = \|\tilde{\mathbf{x}}_i\|^2 - (\mathbf{u}^\top \tilde{\mathbf{x}}_i)^2.$$

En sommant sur  $i$  :

$$\sum_i \|\tilde{\mathbf{x}}_i - z_i \mathbf{u}\|^2 = \underbrace{\sum_i \|\tilde{\mathbf{x}}_i\|^2}_{\text{constante (variance totale)}} - N \mathbf{u}^\top \Sigma \mathbf{u}.$$

Le premier terme ne dépend pas de  $\mathbf{u}$ . Minimiser l'erreur revient donc à **maximiser**  $\mathbf{u}^\top \Sigma \mathbf{u}$ , la variance projetée. (Le cas général  $k$  suit en remplaçant  $\mathbf{u}$  par  $\mathbf{U}$ .)  $\square$

### À retenir

« Garder le plus de variance » et « perdre le moins d'information » sont **le même objectif**. C'est ce qui fait toute la cohérence de l'ACP : variance expliquée + erreur résiduelle = variance totale (constante).

## 4 Cas d'une dimension : pourquoi les vecteurs propres ?

On cherche  $\mathbf{u}$  unitaire maximisant la variance projetée. D'abord, montrons que cette variance vaut  $\mathbf{u}^\top \Sigma \mathbf{u}$  :

$$\text{Var}(z) = \frac{1}{N} \sum_i z_i^2 = \frac{1}{N} \sum_i (\mathbf{u}^\top \tilde{\mathbf{x}}_i)^2 = \mathbf{u}^\top \left( \frac{1}{N} \sum_i \tilde{\mathbf{x}}_i \tilde{\mathbf{x}}_i^\top \right) \mathbf{u} = \mathbf{u}^\top \Sigma \mathbf{u}.$$

On résout donc  $\max_{\|\mathbf{u}\|=1} \mathbf{u}^\top \Sigma \mathbf{u}$  par les multiplicateurs de Lagrange :

$$\mathcal{L}(\mathbf{u}, \lambda) = \mathbf{u}^\top \Sigma \mathbf{u} - \lambda(\mathbf{u}^\top \mathbf{u} - 1), \quad \nabla_{\mathbf{u}} \mathcal{L} = 2\Sigma \mathbf{u} - 2\lambda \mathbf{u} = 0 \implies \boxed{\Sigma \mathbf{u} = \lambda \mathbf{u}}.$$

### À retenir

Les directions candidates sont les **vecteurs propres** de  $\Sigma$ . En remplaçant, la variance projetée vaut  $\mathbf{u}^\top \Sigma \mathbf{u} = \lambda \mathbf{u}^\top \mathbf{u} = \lambda$  : c'est exactement la **valeur propre**. La meilleure direction est celle de plus grande valeur propre.

## 5 Résolution en dimension $k$

$\Sigma$  étant symétrique, on la diagonalise :

$$\Sigma = Q\Lambda Q^\top, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_d), \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d \geq 0.$$

**Théorème 5.1** (Solution optimale). *Le maximum de (1) vaut  $\sum_{i=1}^k \lambda_i$  et est atteint par*

$$\mathbf{U}^* = (q_1 \ \dots \ q_k),$$

où  $q_i$  est le vecteur propre associé à  $\lambda_i$  (les  $k$  plus grandes).

### Intuition

On empile simplement les  $k$  **directions propres dominantes**. Comme elles sont orthogonales, chacune apporte sa propre variance  $\lambda_i$  sans redondance, et leur somme  $\sum_{i \leq k} \lambda_i$  est la variance totale capturée.

### 5.1 Variance expliquée

La variance totale est  $\text{Tr}(\Sigma) = \sum_{j=1}^d \lambda_j$ . Avec  $k$  composantes :

$$\text{variance expliquée} = \sum_{i=1}^k \lambda_i, \quad \text{proportion expliquée} = \frac{\sum_{i=1}^k \lambda_i}{\sum_{j=1}^d \lambda_j}.$$

## 6 Projection, reconstruction et erreur

**Projection (compression).**  $Z = \tilde{\mathbf{X}}\mathbf{U} \in \mathbb{R}^{N \times k}$  : les **scores**, coordonnées réduites.

**Reconstruction.**  $\hat{\mathbf{X}} = \mathbf{Z}\mathbf{U}^\top + \mu = \tilde{\mathbf{X}}\mathbf{U}\mathbf{U}^\top + \mu$  : on revient dans  $\mathbb{R}^d$ .

**Erreur minimale.** L'erreur de reconstruction optimale est la somme des valeurs propres **rejetées** :

$$\min \left\| \mathbf{X} - \hat{\mathbf{X}} \right\|_F^2 = N \sum_{i=k+1}^d \lambda_i. \quad (3)$$

*Pourquoi* : variance totale  $\sum_j \lambda_j$  = variance gardée  $\sum_{i \leq k} \lambda_i$  + variance perdue  $\sum_{i > k} \lambda_i$ . La part perdue est l'erreur.

### À retenir

L'ACP fournit la **meilleure approximation linéaire de rang  $k$**  au sens des moindres carrés : aucune autre projection de même dimension ne fait mieux.

## 7 Lien avec la SVD

La **décomposition en valeurs singulières** des données centrées s'écrit  $\tilde{\mathbf{X}} = \mathbf{W}\mathbf{S}\mathbf{V}^\top$ , avec  $\mathbf{W}, \mathbf{V}$  orthogonales et  $\mathbf{S}$  diagonale (valeurs singulières  $s_i \geq 0$ ). Alors

$$\Sigma = \frac{1}{N} \tilde{\mathbf{X}}^\top \tilde{\mathbf{X}} = \frac{1}{N} \mathbf{V} \mathbf{S} \underbrace{\mathbf{W}^\top \mathbf{W}}_{=\mathbf{I}} \mathbf{S} \mathbf{V}^\top = \frac{1}{N} \mathbf{V} \mathbf{S}^2 \mathbf{V}^\top.$$

On identifie : les **axes ACP** sont les **colonnes de  $\mathbf{V}$**  (vecteurs singuliers à droite), et les valeurs propres sont  $\lambda_i = s_i^2/N$ . Les scores sont  $\mathbf{Z} = \tilde{\mathbf{X}}\mathbf{V} = \mathbf{W}\mathbf{S}$ .

**Théorème 7.1** (Eckart–Young). *La troncature  $\mathbf{X}_k = \sum_{i=1}^k s_i w_i v_i^\top$  est la **meilleure approximation de rang  $k$**  de  $\tilde{\mathbf{X}}$  (en norme de Frobenius et spectrale). C'est la justification théorique de l'ACP par la SVD.*

### ACP par covariance ou par SVD ?

Mathématiquement équivalentes. En pratique, on calcule l'ACP **via la SVD de  $\tilde{\mathbf{X}}$**  : plus stable numériquement (on évite de former  $\Sigma = \tilde{\mathbf{X}}^\top \tilde{\mathbf{X}}$ , qui carre le conditionnement) et plus efficace quand  $d$  est grand.

## 8 Exemple numérique complet

Prenons 5 points de  $\mathbb{R}^2$  :  $(1, 1), (2, 2), (3, 3), (4, 4), (5, 7)$ .

**1. Centrage.**  $\mu = (3, 3,4)$ . Données centrées :

$$\tilde{\mathbf{x}}_1 = (-2, -2,4), \tilde{\mathbf{x}}_2 = (-1, -1,4), \tilde{\mathbf{x}}_3 = (0, -0,4), \tilde{\mathbf{x}}_4 = (1, 0,6), \tilde{\mathbf{x}}_5 = (2, 3,6).$$

**2. Covariance.** Avec  $S_{xx} = 10, S_{yy} = 21,2, S_{xy} = 14$  :

$$\Sigma = \frac{1}{5} \begin{pmatrix} 10 & 14 \\ 14 & 21,2 \end{pmatrix} = \begin{pmatrix} 2 & 2,8 \\ 2,8 & 4,24 \end{pmatrix}.$$

Le terme hors-diagonale 2,8 indique un nuage **incliné** ( $x$  et  $y$  varient ensemble).

**3. Valeurs propres.**  $\det(\Sigma - \lambda \mathbf{I}) = 0$  donne  $\lambda^2 - 6,24\lambda + 0,64 = 0$ , d'où

$$\lambda_1 \approx 6,136, \quad \lambda_2 \approx 0,104.$$

La composante 1 explique  $\frac{\lambda_1}{\lambda_1 + \lambda_2} \approx \frac{6,136}{6,24} \approx 98,3\%$  de la variance.

4. **Vecteur propre principal.** En résolvant  $(\Sigma - \lambda_1 \mathbf{I})\mathbf{u} = 0$  :

$$\mathbf{u}_1 \approx (0,561, 0,828), \quad \mathbf{u}_2 \approx (-0,828, 0,561) \text{ (orthogonal).}$$

5. **Projection (2D  $\rightarrow$  1D).**  $z_i = \mathbf{u}_1^\top \tilde{\mathbf{x}}_i$  :

$$z_1 \approx -3,109, \quad z_2 \approx -1,720, \quad z_3 \approx -0,331, \quad z_4 \approx 1,058, \quad z_5 \approx 4,102.$$

Ces  $z_i$  sont les données compressées sur l'axe principal.

6. **Vérification « variance perdue =  $\lambda_2$  ».** La coordonnée ignorée est  $w_i = \mathbf{u}_2^\top \tilde{\mathbf{x}}_i$  (distance orthogonale à la droite). La moyenne des  $w_i^2$  vaut  $\approx 0,104 \approx \lambda_2$  : la variance perdue égale bien la valeur propre rejetée, illustrant (3).

## 9 Choix du nombre de composantes

- **Variance cumulée** : garder assez de composantes pour atteindre un seuil (p. ex. 90 ou 95 %).
- **Éboulis (scree plot)** : tracer  $\lambda_i$  décroissants et repérer le « coude » (chute brutale).
- **Critère de Kaiser** : garder les composantes de valeur propre  $> 1$  (sur données standardisées).

## 10 Limites et extensions

### Les points faibles de l'ACP

- **Linéarité** : l'ACP ne capte que des structures **linéaires**. Sur une variété courbe (spirale, « swiss roll »), elle échoue.
- **Échelle** : sensible aux unités ; il faut **standardiser** (sinon une variable à grande variance domine artificiellement). ACP sur la covariance vs sur la corrélation.
- **Variance  $\neq$  pertinence** : la direction de plus grande variance n'est pas toujours la plus utile pour une tâche (p. ex. pour séparer des classes).
- **Interprétabilité** : les composantes sont des *combinaisons* de toutes les variables, difficiles à interpréter.
- **Non supervisée** : ignore les étiquettes (pour un objectif de classification, la **LDA** projette plutôt pour séparer les classes).

### Extensions

- **Kernel PCA** : ACP dans un espace de caractéristiques via un noyau  $\Rightarrow$  capture des structures non linéaires (même « kernel trick » que les SVM).
- **t-SNE, UMAP** : réduction non linéaire orientée **visualisation**, préservant le voisinage local.
- **Autoencodeurs** : réseaux de neurones qui apprennent une compression non linéaire ; un autoencodeur linéaire retrouve l'ACP.
- **ICA** : cherche des composantes **indépendantes** (et non seulement décorrélées), utile pour la séparation de sources.

## 11 Synthèse

### À retenir

1. **Centrer** les données (et souvent standardiser).
2. Calculer la covariance  $\Sigma = \frac{1}{N} \tilde{\mathbf{X}}^\top \tilde{\mathbf{X}}$ .
3. **Diagonaliser**  $\Sigma$  (ou faire la SVD de  $\tilde{\mathbf{X}}$ ) ; les directions ACP sont les vecteurs propres, les variances les valeurs propres.
4. Garder les  $k$  plus grandes  $\Rightarrow$  axes principaux ; projeter  $Z = \tilde{\mathbf{X}}\mathbf{U}$ , reconstruire  $\hat{\mathbf{X}} = Z\mathbf{U}^\top + \mu$ .
5. **Variance maximale**  $\Leftrightarrow$  **erreur de reconstruction minimale** ; l'erreur vaut  $\sum_{i>k} \lambda_i$  ; meilleure approximation de rang  $k$  (Eckart–Young).
6. **Limites** : linéaire, sensible à l'échelle, non supervisée  $\Rightarrow$  kernel PCA, t-SNE/UMAP, autoencodeurs, LDA.