

Le clustering hiérarchique ascendant

Linkages, méthode de Ward (avec démonstration),
récurrence de Lance–Williams et dendrogramme

5 juin 2026

Table des matières

1	Cadre : un apprentissage non supervisé	1
2	Principe et algorithme	1
3	Distance entre individus	2
4	Distance entre clusters : les critères de liaison (linkage)	2
4.1	Saut minimal (Single Linkage)	2
4.2	Saut maximal (Complete Linkage)	2
4.3	Saut moyen (Average Linkage, UPGMA)	2
5	La méthode de Ward (avec démonstration)	3
6	La récurrence de Lance–Williams (mise à jour unifiée)	4
7	Le dendrogramme : définition mathématique	4
7.1	Suite de partitions emboîtées	4
7.2	Fonction de hauteur	4
7.3	Dendrogramme et ultramétrie	5
7.4	Coupe du dendrogramme	5
8	Choisir le nombre de clusters	5
9	Synthèse	5

1 Cadre : un apprentissage non supervisé

Le **clustering ascendant hiérarchique** (CAH) est une méthode de classification **non supervisée** : on regroupe des individus similaires en *clusters* sans connaître les étiquettes, et **sans fixer à l’avance le nombre de groupes**. Il est **agglomératif** : chaque individu démarre seul dans son propre cluster, puis on fusionne progressivement les clusters jusqu’à n’en former qu’un.

Agglomératif vs divisif

Il existe deux stratégies hiérarchiques. L’**agglomérative** (CAH, *bottom-up*) part de n clusters et fusionne. La **divisive** (*top-down*, p. ex. DIANA) part d’un cluster unique et le coupe récursivement. La CAH est de loin la plus utilisée car plus simple à calculer. Dans les deux cas, le résultat est une **hiérarchie** de partitions, visualisée par un *dendrogramme*.

2 Principe et algorithme

Soit un ensemble de données $X = \{x_1, \dots, x_n\}$, $x_i \in \mathbb{R}^p$. Au départ, chaque point est un cluster : $C_i = \{x_i\}$.

L'algorithme CAH

À chaque itération :

1. calculer la distance entre tous les couples de clusters ;
2. **fusionner** les deux clusters les plus proches ;
3. **mettre à jour** les distances entre le nouveau cluster et les autres ;

jusqu'à obtenir un unique cluster. Les fusions successives forment une hiérarchie représentée par un **dendrogramme**.

Coût de calcul

Une implémentation naïve coûte $O(n^3)$ (recalcul des distances à chaque étape). Grâce à la **récurrence de Lance-Williams** (section 6), la mise à jour de l'étape 3 devient $O(1)$ par couple, ce qui ramène le coût total à $O(n^2)$. C'est pourquoi la CAH reste limitée aux jeux de données de taille modérée.

3 Distance entre individus

La distance la plus courante est la distance **euclidienne** :

$$d(x, y) = \|x - y\|_2 = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}.$$

D'autres distances conviennent selon les données : **Manhattan** ($\sum_j |x_j - y_j|$, robuste aux valeurs extrêmes), **cosinus** (similarité d'orientation, utile pour le texte), **Hamming** (données catégorielles/binaires).

Standardiser d'abord

Il est fortement recommandé de **standardiser** les variables (centrer-réduire). Sans cela, une variable à grande échelle (p. ex. un revenu en euros) domine la distance et écrase les autres (p. ex. un âge). On veut que chaque variable contribue équitablement.

4 Distance entre clusters : les critères de liaison (linkage)

Une fois la distance entre *points* fixée, il faut définir la distance entre *clusters*. C'est le rôle du **critère de liaison**. Soient deux clusters A et B .

4.1 Saut minimal (Single Linkage)

$$D_{\text{single}}(A, B) = \min_{x \in A, y \in B} d(x, y).$$

Distance entre les deux points les plus *proches*. Tendance au **chaînage** (clusters allongés, « en chaîne ») ; sensible aux points-ponts ; bon pour détecter des formes non convexes.

4.2 Saut maximal (Complete Linkage)

$$D_{\text{complete}}(A, B) = \max_{x \in A, y \in B} d(x, y).$$

Distance entre les deux points les plus *éloignés*. Produit des clusters **compacts** et sphériques ; réduit le chaînage ; sensible aux valeurs aberrantes.

4.3 Saut moyen (Average Linkage, UPGMA)

$$D_{\text{avg}}(A, B) = \frac{1}{|A||B|} \sum_{x \in A} \sum_{y \in B} d(x, y).$$

Moyenne de toutes les distances inter-clusters. **Compromis** entre single et complete ; comportement généralement stable.

Single vs complete, en image

Le single linkage demande « existe-t-il *au moins un* couple de points proches ? » : il suffit d'un pont étroit pour fusionner. Le complete linkage demande « *tous* les points sont-ils proches ? » : il faut que les clusters soient globalement compacts. D'où clusters allongés vs sphériques.

5 La méthode de Ward (avec démonstration)

La méthode de Ward ne part pas d'une distance inter-clusters, mais minimise l'**augmentation de variance intra-cluster** (l'inertie) lors d'une fusion. Pour un cluster C de centroïde $\mu_C = \frac{1}{|C|} \sum_{x \in C} x$, on définit son inertie (somme des carrés des écarts au centre) :

$$\text{SSE}(C) = \sum_{x \in C} \|x - \mu_C\|^2.$$

On fusionne le couple (A, B) qui minimise l'**augmentation d'inertie** :

$$\Delta(A, B) = \text{SSE}(A \cup B) - \text{SSE}(A) - \text{SSE}(B).$$

Proposition 5.1 (Formule de Ward). Avec la distance euclidienne, en notant $n_A = |A|$, $n_B = |B|$,

$$\Delta(A, B) = \frac{n_A n_B}{n_A + n_B} \|\mu_A - \mu_B\|^2 \quad (1)$$

Démonstration. **Lemme (Huygens / théorème de König).** Pour tout cluster C de centroïde μ_C et tout point z :

$$\sum_{x \in C} \|x - z\|^2 = \sum_{x \in C} \|x - \mu_C\|^2 + |C| \|\mu_C - z\|^2.$$

En effet, en écrivant $x - z = (x - \mu_C) + (\mu_C - z)$ et en développant le carré :

$$\sum_{x \in C} \|x - z\|^2 = \sum_{x \in C} \|x - \mu_C\|^2 + 2(\mu_C - z)^T \underbrace{\sum_{x \in C} (x - \mu_C)}_{=0} + |C| \|\mu_C - z\|^2,$$

le terme croisé étant nul car $\sum_{x \in C} (x - \mu_C) = 0$ par définition du centroïde.

Application. Soit $C = A \cup B$, de centroïde $\mu_C = \frac{n_A \mu_A + n_B \mu_B}{n_A + n_B}$. On découpe :

$$\text{SSE}(C) = \sum_{x \in A} \|x - \mu_C\|^2 + \sum_{x \in B} \|x - \mu_C\|^2.$$

Le lemme appliqué à A (avec $z = \mu_C$) donne $\sum_{x \in A} \|x - \mu_C\|^2 = \text{SSE}(A) + n_A \|\mu_A - \mu_C\|^2$, et de même pour B . Donc

$$\Delta(A, B) = \text{SSE}(C) - \text{SSE}(A) - \text{SSE}(B) = n_A \|\mu_A - \mu_C\|^2 + n_B \|\mu_B - \mu_C\|^2.$$

Calcul des écarts au centre commun. En notant $n_C = n_A + n_B$:

$$\mu_A - \mu_C = \mu_A - \frac{n_A \mu_A + n_B \mu_B}{n_C} = \frac{n_B(\mu_A - \mu_B)}{n_C}, \quad \mu_B - \mu_C = \frac{n_A(\mu_B - \mu_A)}{n_C}.$$

On substitue :

$$\Delta(A, B) = n_A \frac{n_B^2}{n_C^2} \|\mu_A - \mu_B\|^2 + n_B \frac{n_A^2}{n_C^2} \|\mu_A - \mu_B\|^2 = \frac{n_A n_B (n_A + n_B)}{n_C^2} \|\mu_A - \mu_B\|^2.$$

Comme $n_A + n_B = n_C$, il reste $\Delta(A, B) = \frac{n_A n_B}{n_C} \|\mu_A - \mu_B\|^2 = \frac{n_A n_B}{n_A + n_B} \|\mu_A - \mu_B\|^2$. $\square$

Intuition

La formule (1) dit que fusionner coûte d'autant plus cher que les centroïdes sont éloignés *et* que les clusters sont gros (facteur $\frac{n_A n_B}{n_A + n_B}$). Ward favorise donc des clusters **homogènes et compacts** : c'est l'analogue hiérarchique du k -means (tous deux minimisent l'inertie intra-cluster). Très utilisé sur données quantitatives standardisées.

6 La récurrence de Lance–Williams (mise à jour unifiée)

Comment recalculer efficacement les distances après une fusion (étape 3 de l'algorithme) ? Tous les linkages classiques suivent une **même formule de mise à jour**. Quand on fusionne A et B en $C = A \cup B$, la distance de C à un autre cluster D s'écrit

$$D(C, D) = \alpha_A D(A, D) + \alpha_B D(B, D) + \beta D(A, B) + \gamma |D(A, D) - D(B, D)|, \quad (2)$$

où les coefficients $(\alpha_A, \alpha_B, \beta, \gamma)$ dépendent du critère choisi :

Critère	α_A	α_B	β	γ
Single	$\frac{1}{2}$	$\frac{1}{2}$	0	$-\frac{1}{2}$
Complete	$\frac{1}{2}$	$\frac{1}{2}$	0	$+\frac{1}{2}$
Average (UPGMA)	$\frac{n_A}{n_A + n_B}$	$\frac{n_B}{n_A + n_B}$	0	0
Ward	$\frac{n_A + n_B}{n_A + n_B + n_D}$	$\frac{n_A + n_B}{n_A + n_B + n_D}$	$-\frac{n_D}{n_A + n_B + n_D}$	0

Single et complete tombent juste

Pour le single linkage, $\frac{1}{2}(a+b) - \frac{1}{2}|a-b| = \min(a, b)$: la formule (2) redonne bien $D(C, D) = \min(D(A, D), D(B, D))$. Pour le complete, $\frac{1}{2}(a+b) + \frac{1}{2}|a-b| = \max(a, b)$: on retrouve le maximum. La même équation encode donc tous les linkages, juste en changeant quatre nombres.

À retenir

Lance–Williams évite de revisiter les points individuels : on met à jour les distances *entre clusters* directement, ce qui rend la CAH praticable ($O(n^2)$).

7 Le dendrogramme : définition mathématique

7.1 Suite de partitions emboîtées

Un dendrogramme représente une suite de partitions hiérarchiques

$$\mathcal{P}_0 \succ \mathcal{P}_1 \succ \cdots \succ \mathcal{P}_{n-1},$$

où $\mathcal{P}_0 = \{\{x_1\}, \dots, \{x_n\}\}$ (partition initiale), $\mathcal{P}_{n-1} = \{X\}$ (partition finale), et $\succ$ désigne le raffinement (fusion). À l'étape t , $\mathcal{P}_t$ contient $n - t$ clusters.

7.2 Fonction de hauteur

À l'étape t , on fusionne A_t et B_t ; on associe à cette fusion la **hauteur**

$$h_t = D(A_t, B_t),$$

où D est la dissimilarité du linkage choisi. Pour les linkages usuels, la suite est **croissante** :

$$0 \leq h_1 \leq h_2 \leq \cdots \leq h_{n-1}.$$

Intuition

La hauteur à laquelle deux clusters se rejoignent mesure leur *dissemblance*. Une fusion « haute » signale que l'on a dû réunir des groupes très différents. (Le single linkage peut produire des *inversions* si l'on utilise certaines variantes ; les linkages standard restent monotones.)

7.3 Dendrogramme et ultramétrie

Vu comme un arbre binaire enraciné (feuilles = individus, nœuds internes = fusions de hauteur h_t), le dendrogramme induit une **ultramétrie** d_u sur X :

$$d_u(x_i, x_j) = \min\{h_t \mid x_i \text{ et } x_j \text{ sont dans le même cluster à l'étape } t\},$$

c'est-à-dire la hauteur à laquelle x_i et x_j se retrouvent réunis pour la première fois.

Propriété 7.1 (Inégalité ultramétrique).

$$d_u(x_i, x_j) \leq \max(d_u(x_i, x_k), d_u(x_k, x_j)) \quad \forall x_i, x_j, x_k \in X.$$

Pourquoi le max et pas la somme ?

L'inégalité triangulaire ordinaire utilise une somme ; l'ultramétrie la renforce avec un max. Concrètement : parmi trois points, les **deux plus grandes** des trois hauteurs de fusion sont égales. Si x_i et x_k se rejoignent à hauteur 5, et x_k et x_j à hauteur 8, alors x_i et x_j se rejoignent aussi à hauteur 8 (le moment où le gros cluster absorbe tout). C'est la signature des structures arborescentes.

7.4 Coupe du dendrogramme

Pour un seuil $\lambda > 0$, la coupe horizontale à la hauteur λ définit une partition :

$$\mathcal{P}_\lambda = \{C \subset X \mid \forall x_i, x_j \in C, d_u(x_i, x_j) \leq \lambda\}.$$

Le nombre de clusters est le nombre de branches coupées.

8 Choisir le nombre de clusters

On ne fixe pas k a priori : on lit le dendrogramme. La règle pratique est de **couper juste avant un grand saut** de hauteur de fusion :

- un **saut important** entre h_t et h_{t+1} signale que la fusion suivante réunit des groupes naturellement séparés ;
- on coupe donc à une hauteur λ située dans ce grand intervalle ;
- le seuil λ règle le compromis **granularité** (beaucoup de petits clusters) vs **homogénéité** (peu de gros clusters).

C'est l'analogie, sur le dendrogramme, de la « méthode du coude ».

9 Synthèse

Linkage	Comportement	Sensibilité
Single	Connectivité, clusters allongés, formes non convexes	Chaînage, points-ponts
Complete	Clusters compacts, sphériques	Valeurs aberrantes
Average	Compromis stable	Modérée
Ward	Minimise la variance intra-cluster (compact, homogène)	Données quantitatives standardisées

À retenir

- La CAH fusionne itérativement les clusters les plus proches selon un **linkage**.
- Le choix du linkage détermine la forme des clusters (single = connectivité, complete = compacité, average = compromis, Ward = inertie minimale).
- Ward minimise l'augmentation d'inertie : $\Delta(A, B) = \frac{n_A n_B}{n_A + n_B} \|\mu_A - \mu_B\|^2$.
- La **récurrence de Lance-Williams** unifie tous les linkages et rend la mise à jour efficace.
- Le **dendrogramme** équivaut à une suite de partitions emboîtées, à un arbre binaire pondéré, et à une ultramétrie. On le coupe juste avant un grand saut de hauteur.