

K-means, *K*-means++ et spectral clustering

Théorie, démonstrations, limites et extensions

5 juin 2026

Table des matières

1	Cadre : le partitionnement en k groupes	1
2	Formulation mathématique	1
2.1	Intuition géométrique : le diagramme de Voronoï	1
3	L'algorithme de Lloyd	2
3.1	Démonstration : pourquoi la moyenne ?	2
3.2	Critère d'arrêt	2
4	Convergence	2
5	Distances et complexité	3
6	Les limites de <i>K</i>-means (en détail)	3
7	<i>K</i>-means++ : une initialisation intelligente	4
7.1	Le problème	4
7.2	L'algorithme d'amorçage (seeding)	4
7.3	Garantie théorique	4
8	Spectral clustering	4
8.1	Motivation	4
8.2	Le graphe de similarité	4
8.3	Le Laplacien du graphe	5
8.4	Lien avec la coupe de graphe (relaxation)	5
8.5	L'algorithme	6
8.6	Limites du spectral clustering	6
9	Synthèse comparative	6

1 Cadre : le partitionnement en k groupes

Le ***K*-means** (k -moyennes) est une méthode de clustering **non supervisé**. À partir d'un ensemble $X = \{x_1, \dots, x_n\}$, $x_i \in \mathbb{R}^d$, on cherche à former k clusters **homogènes et compacts**, chacun résumé par son **centroïde** $\mu_j \in \mathbb{R}^d$.

2 Formulation mathématique

On partitionne X en k clusters $\mathcal{C} = \{C_1, \dots, C_k\}$. K -means minimise l'inertie **intra-cluster** (somme des carrés des distances aux centroïdes) :

$$J(\mathcal{C}, \mu) = \sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - \mu_j\|^2. \quad (1)$$

Intuition

J mesure à quel point les points sont « serrés » autour de leur centre. La minimiser revient à chercher des clusters *compacts*. Le problème exact est **NP-difficile** : on ne sait pas trouver l'optimum global en temps raisonnable, d'où un algorithme itératif (Lloyd) qui converge vers un optimum *local*.

2.1 Intuition géométrique : le diagramme de Voronoï

Chaque point est assigné au centroïde le plus proche. L'espace se découpe ainsi en cellules : c'est un **diagramme de Voronoï**. Conséquence importante : les frontières entre clusters sont des **hyperplans**, donc les clusters K -means sont toujours **convexes** (on y reviendra dans les limites).

3 L'algorithme de Lloyd

Les deux étapes alternées

1. **Initialisation** : choisir k centroïdes $\mu_1^{(0)}, \dots, \mu_k^{(0)}$.
2. **Assignment** : affecter chaque point au centroïde le plus proche,

$$C(x_i) = \arg \min_j \|x_i - \mu_j\|^2.$$

3. **Mise à jour** : recalculer chaque centroïde comme la moyenne de son cluster,

$$\mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i.$$

4. **Répéter** 2–3 jusqu'au critère d'arrêt.

3.1 Démonstration : pourquoi la moyenne ?

Proposition 3.1. À assignment fixée, le centroïde qui minimise l'inertie d'un cluster C_j est la **moyenne empirique** de ses points.

Démonstration. On dérive $J_j(\mu_j) = \sum_{x_i \in C_j} \|x_i - \mu_j\|^2$ par rapport à μ_j :

$$\nabla_{\mu_j} J_j = \sum_{x_i \in C_j} 2(\mu_j - x_i) = 2\left(|C_j| \mu_j - \sum_{x_i \in C_j} x_i\right).$$

L'annulation donne $|C_j| \mu_j = \sum_{x_i \in C_j} x_i$, soit $\mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i$. La hessienne $2|C_j|\mathbf{I}$ étant définie positive, c'est bien un minimum. $\square$

Les deux étapes minimisent la *même* fonction

L'étape d'**assignation** minimise J à centroïdes fixés (chaque point va au plus proche). L'étape de **mise à jour** minimise J à assignation fixée (la moyenne). C'est une **minimisation alternée** : on optimise tour à tour les deux groupes de variables.

3.2 Critère d'arrêt

On s'arrête si les centroïdes ne bougent plus ($\|\mu_j^{(t)} - \mu_j^{(t-1)}\| < \varepsilon$), si les clusters sont inchangés, ou si un nombre maximal d'itérations est atteint.

4 Convergence

Théorème 4.1. *L'algorithme de Lloyd fait décroître J à chaque étape et termine en un nombre fini d'itérations.*

Pourquoi

Les deux étapes ne peuvent qu'abaisser (ou laisser égal) J : la suite $J^{(0)} \geq J^{(1)} \geq \dots \geq 0$ est décroissante et minorée par 0, donc **convergente**. De plus, il n'existe qu'un nombre *fini* de partitions possibles ($\leq k^n$) ; comme J décroît strictement à chaque changement de partition, l'algorithme ne peut pas boucler et atteint un **point fixe**.

Optimum local seulement

La convergence est garantie, mais **pas vers le minimum global**. Selon l'initialisation, on peut rester piégé dans un mauvais optimum local. C'est exactement le problème que résout K -means++ (section 7).

5 Distances et complexité

La distance naturelle de K -means est l'**euclidienne au carré** (c'est elle qui rend la moyenne optimale). D'autres distances existent (Manhattan L_1 , Minkowski L_p , Chebyshev L_∞ , cosinus), mais changer de distance change la statistique optimale du centre : avec L_1 on obtient le **k -medians** (la médiane), avec une dissimilarité générale le **k -medoids** (un point réel du cluster).

La complexité d'une itération est $O(nkd)$, soit au total

$$O(n \cdot k \cdot d \cdot i),$$

où i est le nombre d'itérations. C'est ce qui rend K -means très rapide, même sur de grands jeux de données.

6 Les limites de K -means (en détail)

K -means repose sur des hypothèses fortes. Les connaître permet de savoir *quand il échoue*.

1. Clusters sphériques et de variance similaire

L'objectif (1) suppose implicitement des clusters **isotropes** (ronds) et de **taille/variance comparables**. Sur des clusters allongés, de densités ou d'effectifs très différents, K -means découpe mal (il tend à couper les gros clusters et fusionner les petits).

2. Clusters non convexes : l'échec fondamental

Les cellules de Voronoï étant convexes, K -means ne peut produire que des frontières linéaires. Il **échoue complètement** sur des formes non convexes : deux **cercles concentriques**, deux **lunes** entrelacées, des spirales... Aucune partition par hyperplans ne sépare ces structures. C'est la motivation directe du **spectral clustering** (section 8).

3. Sensibilité à l'initialisation

Des centroïdes initiaux mal placés mènent à un mauvais optimum local. Remèdes : relancer plusieurs fois et garder le meilleur J (`n_init`), ou mieux, initialiser avec K -means++.

4. Choix de k à l'avance

k doit être fixé avant. On le choisit par la **méthode du coude** (tracer J en fonction de k et repérer le « coude »), le **score de silhouette**, ou des critères comme le gap statistic.

5. Sensibilité aux valeurs aberrantes

La moyenne n'est pas robuste : un seul outlier déplace fortement un centroïde. Le k -medoids (centre = point réel) ou un prétraitement des outliers sont plus sûrs.

6. Assignment « dure » et grande dimension

Chaque point appartient à un seul cluster (pas de notion d'appartenance partielle ; les *modèles de mélange gaussien* offrent une assignment « molle »). En très grande dimension, les distances se concentrent (fléau de la dimension) et perdent leur pouvoir discriminant.

7 K -means++ : une initialisation intelligente

7.1 Le problème

L'initialisation aléatoire uniforme peut placer plusieurs centres dans le même groupe dense, laissant d'autres groupes sans centre $\Rightarrow$ mauvais optimum local. K -means++ (Arthur & Vassilvitskii, 2007) choisit des centres initiaux **bien répartis**.

7.2 L'algorithme d'amorçage (seeding)

On note $D(x)$ la distance de x au centre déjà choisi *le plus proche*.

1. Choisir le **premier** centre μ_1 uniformément au hasard parmi les points.
2. Choisir chaque centre suivant x avec une **probabilité proportionnelle à $D(x)^2$** :

$$\mathbb{P}(\text{choisir } x) = \frac{D(x)^2}{\sum_{x' \in X} D(x')^2}.$$

3. Répéter jusqu'à avoir k centres, puis lancer Lloyd normalement.

Pourquoi $D(x)^2$?

Plus un point est *loin* des centres déjà choisis, plus il a de chances d'être sélectionné. On « étale » donc volontairement les centres dans des régions encore non couvertes, tout en gardant de l'aléatoire (on ne prend pas systématiquement le plus lointain, ce qui serait sensible aux outliers).

7.3 Garantie théorique

Théorème 7.1 (Arthur–Vassilvitskii). *L’inertie attendue de la solution K -means++ vérifie*

$$\mathbb{E}[J] \leq 8(\ln k + 2) J_{OPT},$$

où J_{OPT} est l’optimum global. L’amorçage est donc $O(\log k)$ -**compétitif**, avant même la première itération de Lloyd.

En pratique : meilleures solutions, convergence plus rapide. C’est l’initialisation **par défaut** de `scikit-learn`.

8 Spectral clustering

8.1 Motivation

K -means échoue sur les clusters non convexes car il raisonne par distances euclidiennes globales. Le **spectral clustering** change de point de vue : il raisonne sur un **graphe de similarité** et exploite la **connectivité**. Deux points reliés par un chemin de voisins proches finissent dans le même cluster, même s’ils sont euclidiennement éloignés (idéal pour les lunes, les cercles concentriques).

8.2 Le graphe de similarité

On construit un graphe pondéré dont les sommets sont les points et les arêtes encodent la similarité. La matrice d’**affinité** $\mathbf{W}$ (symétrique, $W_{ij} \geq 0$) se construit souvent par :

- **k plus proches voisins** : $W_{ij} = 1$ si x_j est parmi les voisins de x_i ;
- **noyau gaussien (RBF)** : $W_{ij} = \exp(-\|x_i - x_j\|^2 / (2\sigma^2))$, qui décroît vite avec la distance.

On définit le **degré** $d_i = \sum_j W_{ij}$ et la matrice diagonale $\mathbf{D} = \text{diag}(d_1, \dots, d_n)$.

8.3 Le Laplacien du graphe

Définition 8.1 (Laplacien non normalisé).

$$\mathbf{L} = \mathbf{D} - \mathbf{W}.$$

Versions normalisées : $\mathbf{L}_{\text{sym}} = \mathbf{I} - \mathbf{D}^{-1/2} \mathbf{W} \mathbf{D}^{-1/2}$ et $\mathbf{L}_{\text{rw}} = \mathbf{I} - \mathbf{D}^{-1} \mathbf{W}$.

Proposition 8.1 (Propriété fondamentale). *Pour tout vecteur $f \in \mathbb{R}^n$,*

$$f^\top \mathbf{L} f = \frac{1}{2} \sum_{i,j=1}^n W_{ij} (f_i - f_j)^2.$$

*En particulier $\mathbf{L}$ est **symétrique semi-définie positive**, sa plus petite valeur propre est 0 (vecteur propre $\mathbf{1}$), et la **multiplicité de la valeur propre 0** égale le **nombre de composantes connexes** du graphe.*

Démonstration. On développe, en utilisant $d_i = \sum_j W_{ij}$:

$$f^\top \mathbf{L} f = f^\top \mathbf{D} f - f^\top \mathbf{W} f = \sum_i d_i f_i^2 - \sum_{i,j} W_{ij} f_i f_j.$$

On symétrise le premier terme via $\sum_i d_i f_i^2 = \frac{1}{2} (\sum_i d_i f_i^2 + \sum_j d_j f_j^2) = \frac{1}{2} \sum_{i,j} W_{ij} (f_i^2 + f_j^2)$. Donc

$$f^\top \mathbf{L} f = \frac{1}{2} \sum_{i,j} W_{ij} (f_i^2 + f_j^2) - \sum_{i,j} W_{ij} f_i f_j = \frac{1}{2} \sum_{i,j} W_{ij} (f_i^2 - 2f_i f_j + f_j^2) = \frac{1}{2} \sum_{i,j} W_{ij} (f_i - f_j)^2.$$

Comme $W_{ij} \geq 0$, cette quantité est ≥ 0 : $\mathbf{L}$ est semi-définie positive. Pour $f = \mathbf{1}$, $f_i - f_j = 0$ donc $\mathbf{L}\mathbf{1} = \mathbf{0}$: 0 est valeur propre. $\square$

Que mesure $f^T \mathbf{L} f$?

C'est une **énergie de lissage** : elle est petite quand f varie peu entre points *fortement reliés* (gros W_{ij}). Les vecteurs propres associés aux **plus petites** valeurs propres sont donc « les plus lisses » sur le graphe : ils restent quasi constants à l'intérieur d'un groupe bien connecté et changent entre groupes. Ce sont des **indicateurs de clusters** relaxés.

8.4 Lien avec la coupe de graphe (relaxation)

Partitionner le graphe revient à minimiser une **coupe** (somme des poids des arêtes coupées) tout en gardant des groupes équilibrés, p. ex. le RatioCut :

$$\text{RatioCut}(C_1, \dots, C_k) = \sum_{j=1}^k \frac{\text{cut}(C_j, \overline{C_j})}{|C_j|}.$$

Ce problème est NP-difficile (les indicatrices de clusters sont discrètes). En **relaxant** ces indicatrices en vecteurs réels orthonormés $\mathbf{H}$, on montre que

$$\text{RatioCut} \propto \text{Tr}(\mathbf{H}^T \mathbf{L} \mathbf{H}), \quad \text{minimisé sous } \mathbf{H}^T \mathbf{H} = \mathbf{I}.$$

Par le théorème de Courant–Fischer (Rayleigh–Ritz), la solution est donnée par les k **vecteurs propres de plus petites valeurs propres** de $\mathbf{L}$. (Le Ncut conduit de même à $\mathbf{L}_{\text{sym}}$.)

8.5 L'algorithme

Spectral clustering (Ng–Jordan–Weiss)

1. Construire l'affinité $\mathbf{W}$ (k-NN ou noyau gaussien) et le Laplacien (normalisé).
2. Calculer les k **vecteurs propres** de plus petites valeurs propres ; les empiler en colonnes pour former $\mathbf{U} \in \mathbb{R}^{n \times k}$.
3. (Normaliser les lignes de $\mathbf{U}$.) Chaque *ligne* est la nouvelle représentation d'un point dans $\mathbb{R}^k$.
4. Appliquer **K-means** sur les lignes de $\mathbf{U}$.

Le cœur de l'astuce

Le passage par les vecteurs propres « **déplicie** » les données : dans le nouvel espace $\mathbb{R}^k$, les clusters non convexes (lunes, cercles) deviennent des **paquets compacts et linéairement séparables**. K -means, inefficace dans l'espace d'origine, fonctionne alors parfaitement sur cette représentation. Le spectral clustering = *changement de représentation* + K -means.

8.6 Limites du spectral clustering

Coût et réglages

- **Coût** : la décomposition spectrale est $O(n^3)$ en général $\Rightarrow$ mal adapté aux très grands n (on utilise alors des approximations comme Nyström).
- **Hyperparamètres sensibles** : le choix de σ (largeur du noyau) et du graphe de voisinage influence fortement le résultat.
- k à **fixer** : comme K -means, le nombre de clusters reste à choisir (l'« eigengap », l'écart entre valeurs propres successives, aide à le repérer).

9 Synthèse comparative

Méthode	Idée	Forces	Coût
K -means	Minimiser l'inertie ; centres = moyennes	Simple, très rapide	$O(nkdi)$
K -means++	K -means + amorçage $\propto D(x)^2$	Meilleurs optima, $O(\log k)$ -compétitif	$\approx K$ -means
Spectral	Vecteurs propres du Laplacien + K -means	Gère les clusters non convexes	$O(n^3)$

À retenir

- **K -means** minimise l'inertie par minimisation alternée (assignation au plus proche / moyenne). Rapide, mais limité aux clusters **convexes**, **sphériques**, sensible à l'initialisation et aux outliers, et k doit être fixé.
- **K -means++** corrige l'initialisation en étalant les centres ($\mathbb{P} \propto D(x)^2$), avec une garantie $\mathbb{E}[J] \leq 8(\ln k + 2)J_{\text{OPT}}$.
- **Spectral clustering** gère les clusters **non convexes** en passant par le Laplacien du graphe de similarité : on plonge les points via les k plus petits vecteurs propres, puis on applique K -means dans cet espace où les clusters redeviennent compacts.