

Les k plus proches voisins (k -NN)

Théorie, choix de k , fléau de la dimension
et garanties asymptotiques

5 juin 2026

Table des matières

1	Cadre mathématique	1
2	Distances utilisées	1
3	Définition des k plus proches voisins	2
4	k -NN en régression	2
5	k -NN en classification	2
6	Interprétation : un estimateur à noyau adaptatif	3
7	Le choix de k : un compromis biais-variance	3
7.1	Frontière de décision	4
8	Garanties asymptotiques	4
8.1	Consistance de Stone	4
8.2	Le 1-NN : au plus deux fois l'erreur de Bayes	4
9	Le fléau de la dimension (en détail)	4
10	Limites et aspects pratiques	5
11	Synthèse	5

1 Cadre mathématique

Soit $(\mathcal{X}, d)$ un espace métrique, où $\mathcal{X} \subset \mathbb{R}^p$ est l'espace des observations et $d : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}_+$ une distance. On observe un échantillon d'apprentissage i.i.d.

$$\mathcal{D}_n = \{(X_1, Y_1), \dots, (X_n, Y_n)\}, \quad X_i \in \mathcal{X}, \quad Y_i \in \mathcal{Y} = \begin{cases} \mathbb{R} & (\text{régression}), \\ \{1, \dots, C\} & (\text{classification}). \end{cases}$$

Apprentissage « paresseux »

Le k -NN est l'archetype de l'apprentissage **par instances** (*lazy learning*) : il n'y a **aucune phase d'entraînement**, on se contente de stocker les données. Tout le calcul a lieu *au moment de la prédiction*, en cherchant les voisins. C'est aussi un modèle **non paramétrique** : on ne suppose aucune forme fonctionnelle a priori.

2 Distances utilisées

Le choix de la distance est central : c'est lui qui définit « proche ».

$$\text{Euclidienne } (L_2) : d_2(x, x') = \|x - x'\|_2 = \left(\sum_j (x_j - x'_j)^2 \right)^{1/2},$$

$$\text{Manhattan } (L_1) : d_1(x, x') = \sum_j |x_j - x'_j|,$$

$$\text{Minkowski } (L_r), r \geq 1 : d_r(x, x') = \left(\sum_j |x_j - x'_j|^r \right)^{1/r},$$

$$\text{Chebyshev } (L_\infty) : d_\infty(x, x') = \max_j |x_j - x'_j|,$$

$$\text{Mahalanobis} : d_M(x, x') = \sqrt{(x - x')^\top \Sigma^{-1} (x - x')},$$

$$\text{Cosinus} : d_{\cos}(x, x') = 1 - \frac{\langle x, x' \rangle}{\|x\|_2 \|x'\|_2}.$$

Laquelle choisir ?

- **Euclidienne** : par défaut, pour des données numériques homogènes.
- **Manhattan** : plus robuste en grande dimension et aux valeurs extrêmes.
- **Mahalanobis** : tient compte de la **corrélation** et de l'**échelle** des variables (via Σ^{-1}) ; revient à une euclidienne sur des données « blanchies ».
- **Cosinus** : compare les **orientations**, pas les magnitudes (texte, vecteurs creux).

Standardiser les variables est presque toujours indispensable : sinon une variable à grande échelle domine la distance.

3 Définition des k plus proches voisins

Pour un point requête $x \in \mathcal{X}$, on ordonne les observations par distance croissante :

$$d(x, X_{(1)}) \leq d(x, X_{(2)}) \leq \dots \leq d(x, X_{(n)}).$$

Définition 3.1 (Voisinage). L'ensemble des k plus proches voisins de x est

$$\mathcal{N}_k(x) = \{X_{(1)}, \dots, X_{(k)}\}.$$

On note $Y_{(i)}(x)$ l'étiquette du i -ème voisin de x .

4 k -NN en régression

On estime la fonction de régression $m(x) = \mathbb{E}[Y \mid X = x]$ par la **moyenne locale** des étiquettes des voisins :

$$\hat{m}_k(x) = \frac{1}{k} \sum_{i=1}^k Y_{(i)}(x). \quad (1)$$

Intuition

$\mathbb{E}[Y \mid X = x]$ est une moyenne « dans un voisinage infinitésimal de x ». Comme on ne dispose pas d'une infinité de points exactement en x , on approxime ce voisinage par les k points les plus proches et on moyenne : c'est un estimateur **local** et **adaptatif** (le voisinage est plus large là où les données sont rares).

5 k -NN en classification

Le classifieur idéal est celui de **Bayes** (qui minimise l'erreur) :

$$g^*(x) = \arg \max_{c \in \mathcal{Y}} \mathbb{P}(Y = c \mid X = x).$$

Comme on ne connaît pas les probabilités a posteriori, on les estime par la **proportion** de chaque classe parmi les voisins :

$$\hat{\mathbb{P}}_k(Y = c \mid X = x) = \frac{1}{k} \sum_{i=1}^k \mathbb{1}_{\{Y_{(i)}(x)=c\}},$$

puis on prédit la classe majoritaire (**vote majoritaire**) :

$$\hat{g}_k(x) = \arg \max_{c \in \mathcal{Y}} \sum_{i=1}^k \mathbb{1}_{\{Y_{(i)}(x)=c\}}. \quad (2)$$

Vote pondéré

On peut pondérer chaque voisin par l'inverse de sa distance, $w_i = 1/d(x, X_{(i)})$ (ou un noyau), afin que les voisins les plus proches comptent davantage. Cela lisse les frontières et réduit l'effet des égalités. En binaire, on choisit k **impair** pour éviter les votes à égalité.

6 Interprétation : un estimateur à noyau adaptatif

Le k -NN s'écrit comme un estimateur à noyau à **fenêtre variable** :

$$\hat{m}_k(x) = \frac{\sum_{i=1}^n Y_i \mathbb{1}_{\{d(X_i, x) \leq h(x)\}}}{\sum_{i=1}^n \mathbb{1}_{\{d(X_i, x) \leq h(x)\}}},$$

où $h(x)$ est choisi pour que la boule $B(x, h(x))$ contienne *exactement* k points.

Noyau à fenêtre fixe vs k -NN

Un estimateur à noyau classique (Nadaraya–Watson) fixe la **largeur** h et laisse varier le *nombre* de points. Le k -NN fait l'inverse : il fixe le **nombre** k et laisse varier la largeur $h(x)$. C'est pourquoi le k -NN s'adapte à la densité locale : voisinages étroits où les données abondent, larges où elles sont rares.

7 Le choix de k : un compromis biais–variance

C'est le paramètre crucial. Modélisons les étiquettes des voisins par $Y_{(i)} = m(X_{(i)}) + \varepsilon_i$ avec $\mathbb{E}[\varepsilon_i] = 0$, $\text{Var}(\varepsilon_i) = \sigma^2$ indépendants.

Variance. La variance de l'estimateur (1) est

$$\text{Var}(\hat{m}_k(x)) = \text{Var}\left(\frac{1}{k} \sum_{i=1}^k Y_{(i)}\right) = \frac{1}{k^2} \sum_{i=1}^k \text{Var}(\varepsilon_i) = \frac{\sigma^2}{k}.$$

Elle **décroît** en $1/k$: plus de voisins $\Rightarrow$ moins de bruit.

Biais. Le biais est $\frac{1}{k} \sum_i m(X_{(i)}) - m(x)$. Quand k augmente, le voisinage s'élargit, ses points s'éloignent de x , et la moyenne de leurs vraies valeurs $m(X_{(i)})$ s'écarte de $m(x)$: le biais **croît** avec k .

Le compromis

$$\text{MSE}(x) \approx \underbrace{\text{biais}^2(k)}_{\nearrow \text{ avec } k} + \underbrace{\frac{\sigma^2}{k}}_{\searrow \text{ avec } k}.$$

- k **petit** (ex. $k = 1$) : biais faible, **variance élevée**. Frontière de décision très découpée, sensible au bruit (*surapprentissage*).
- k **grand** : variance faible, **biais élevé**. Frontière très lisse, qui peut effacer la vraie structure (*sous-apprentissage*).

On choisit k par **validation croisée** (souvent $k \approx \sqrt{n}$ comme ordre de grandeur).

7.1 Frontière de décision

Pour $k = 1$, la frontière correspond au **diagramme de Voronoï** des points d'apprentissage : chaque point requête hérite de l'étiquette de la cellule dans laquelle il tombe. Augmenter k revient à moyenner sur plusieurs cellules, ce qui régularise (lisse) la frontière.

8 Garanties asymptotiques

8.1 Consistance de Stone

Théorème 8.1 (Stone). *Si $k \rightarrow \infty$ et $k/n \rightarrow 0$ quand $n \rightarrow \infty$, alors le k -NN est **universellement consistant** :*

$$\hat{m}_k(x) \xrightarrow{\mathbb{P}} m(x), \quad \mathbb{P}(\hat{g}_k(X) \neq Y) \rightarrow \mathbb{P}(g^*(X) \neq Y) \text{ (erreur de Bayes)}.$$

Lire les deux conditions

$k \rightarrow \infty$ assure que la moyenne porte sur beaucoup de points $\Rightarrow$ **variance** $\rightarrow 0$. $k/n \rightarrow 0$ assure que le voisinage *rétrécit* (les k voisins se concentrent autour de x) $\Rightarrow$ **biais** $\rightarrow 0$. Les deux conditions encodent exactement le compromis biais-variance, porté à la limite.

8.2 Le 1-NN : au plus deux fois l'erreur de Bayes

Théorème 8.2 (Cover–Hart, 1967). *Quand $n \rightarrow \infty$, l'erreur du classifieur 1-NN, notée R_{1NN} , est encadrée par l'erreur de Bayes R^* :*

$$R^* \leq R_{1NN} \leq 2R^* \left(1 - \frac{C}{C-1} R^*\right) \leq 2R^*.$$

Intuition

Résultat célèbre : même le plus simple des voisinages (un seul voisin !) atteint au pire **le double** de l'erreur optimale. Autrement dit, « la moitié de l'information de classification est contenue dans le plus proche voisin ». C'est ce qui justifie la réputation du k -NN comme baseline redoutable.

9 Le fléau de la dimension (en détail)

Le talon d'Achille du k -NN. En grande dimension, la notion de « voisinage proche » perd son sens.

Les voisinages ne sont plus locaux. Pour capturer une fraction r des données dans un hypercube unité de dimension p , l'arête du sous-cube voisin doit mesurer $\ell = r^{1/p}$.

Fraction r	$p = 2$	$p = 10$	$p = 100$
0,01	0,10	0,63	0,95
0,10	0,32	0,79	0,98

En dimension 100, capturer seulement 1 % des points exige un voisinage couvrant 95 % de l'étendue de *chaque* axe : ce n'est plus du tout « local ».

Concentration des distances. En grande dimension, toutes les paires de points tendent vers la *même* distance :

$$\frac{d_{\max} - d_{\min}}{d_{\min}} \xrightarrow{p \rightarrow \infty} 0.$$

Le plus proche et le plus lointain voisin deviennent indiscernables : le classement par distance, cœur du k -NN, perd son pouvoir discriminant.

Intuition

Conséquence pratique : en grande dimension, le k -NN se dégrade fortement. Remèdes : **réduction de dimension** (ACP, sélection de variables), distances apprises (Mahalanobis, metric learning), ou retirer les variables non pertinentes (le k -NN ne les ignore pas tout seul).

10 Limites et aspects pratiques

Les points faibles du k -NN

- **Fléau de la dimension** : performances qui s'effondrent quand p grandit.
- **Coût à la prédiction** : une requête naïve coûte $O(np)$ (comparer à tous les points). Lourd pour de grands n , et il faut **stocker tout le jeu** en mémoire.
- **Sensibilité à l'échelle et aux variables non pertinentes** : sans standardisation ni sélection, les mauvaises variables polluent la distance.
- **Classes déséquilibrées** : la classe majoritaire tend à remporter les votes ; on corrige par pondération ou rééchantillonnage.
- **Sensibilité au bruit** pour k petit, au choix de la distance en général.

Accélérer la recherche des voisins

Plutôt que de comparer à tous les points, on utilise des structures spatiales : **KD-tree** (efficace en faible dimension), **Ball-tree** (mieux en dimension modérée), ou des méthodes de **voisins approchés** (ANN, LSH, HNSW) qui sacrifient l'exactitude pour la vitesse sur de très grands jeux.

11 Synthèse

À retenir

- Le k -NN est **non paramétrique** et **paresseux** : pas d'entraînement, tout le calcul est reporté à la prédiction.
 - **Régression** : moyenne des k voisins ; **classification** : vote majoritaire (estimation empirique de $\mathbb{P}(Y = c \mid x)$).
 - Le paramètre k règle le **compromis biais–variance** : variance $= \sigma^2/k$ (décroît), biais qui croît avec k . On le choisit par validation croisée.
 - **Garanties** : consistant si $k \rightarrow \infty$, $k/n \rightarrow 0$ (Stone) ; le 1-NN atteint au pire $2\times$ l'erreur de Bayes (Cover–Hart).
 - **Limite majeure** : le **fléau de la dimension** (voisinages non locaux, distances qui se concentrent) et le coût de prédiction. À combiner avec réduction de dimension et structures d'accélération.
-