

La régression logistique

Du tout début, avec démonstrations détaillées,
interprétation des termes (odds, logit) et régularisation

5 juin 2026

Table des matières

1	Le problème : la classification binaire	2
2	Pourquoi pas la régression linéaire ?	2
2.1	Rappel : le modèle linéaire	2
2.2	Le problème en classification	2
3	Les odds et le logit : l'origine de la sigmoïde	3
3.1	Qu'est-ce qu'une « cote » (odds) ?	3
3.2	Le logit : passer de $(0, +\infty)$ à $\mathbb{R}$	3
3.3	Hypothèse fondamentale : un logit linéaire	3
3.4	Dérivation de la sigmoïde (calcul complet)	4
3.5	Propriétés de la sigmoïde	4
3.6	Dérivée de la sigmoïde (calcul complet)	4
4	Interprétation des coefficients : l'odds ratio	5
5	La fonction de coût par maximum de vraisemblance (MLE)	5
5.1	Modèle probabiliste : Bernoulli conditionnelle	5
5.2	Vraisemblance puis log-vraisemblance	5
5.3	De la maximisation à la minimisation : l'entropie croisée	6
6	Gradients : dérivations pas à pas	6
6.1	Dérivée de L par rapport à z	6
6.2	Gradient par rapport à $\mathbf{w}$	7
6.3	Gradient par rapport à b	7
7	Pourquoi pas de solution fermée ?	7
8	Hessienne et convexité	7
8.1	Calcul de la Hessienne	7
8.2	La fonction de coût est convexe	8
9	Optimisation : descente de gradient et Newton / IRLS	8
9.1	Descente de gradient	8
9.2	Newton–Raphson / IRLS	8
10	Régularisation	8
10.1	Pourquoi régulariser ?	8
10.2	Régularisation L2 (Ridge)	9
10.3	Régularisation L1 (Lasso)	9
10.4	Elastic Net : combiner L1 et L2	10
10.5	L1 vs L2 : tableau récapitulatif	10

1 Le problème : la classification binaire

On dispose d'un jeu de données *supervisé* de m exemples :

$$\{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^m, \quad \mathbf{x}^{(i)} \in \mathbb{R}^n, \quad y^{(i)} \in \{0, 1\}.$$

Chaque $\mathbf{x}^{(i)}$ est un vecteur de n *caractéristiques* (features), et $y^{(i)}$ est l'étiquette : 1 pour la classe positive, 0 pour la classe négative.

Objectif. Construire un modèle qui, pour une nouvelle entrée $\mathbf{x}$, prédit la *probabilité* que $\mathbf{x}$ appartienne à la classe 1 :

$$p(\mathbf{x}) = \mathbb{P}(y = 1 \mid \mathbf{x}) \in (0, 1).$$

Intuition

On ne veut pas seulement une réponse « oui / non », mais une *probabilité*. Dire « 0,92 » est plus riche que « oui » : cela encode à la fois la prédiction et la confiance. La régression logistique est le modèle de référence pour produire cette probabilité.

2 Pourquoi pas la régression linéaire ?

2.1 Rappel : le modèle linéaire

La régression linéaire modélise une sortie continue par

$$\hat{y} = \mathbf{w}^\top \mathbf{x} + b,$$

où $\mathbf{w} \in \mathbb{R}^n$ est le vecteur de poids et $b \in \mathbb{R}$ le biais. On ajuste $(\mathbf{w}, b)$ en minimisant l'erreur quadratique moyenne (MSE) :

$$J_{\text{lin}}(\mathbf{w}, b) = \frac{1}{2m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2 = \frac{1}{2m} \sum_{i=1}^m (\mathbf{w}^\top \mathbf{x}^{(i)} + b - y^{(i)})^2.$$

2.2 Le problème en classification

Si $y \in \{0, 1\}$, le score $\mathbf{w}^\top \mathbf{x} + b$ peut prendre *n'importe quelle valeur réelle* dans $(-\infty, +\infty)$. On ne peut donc pas l'interpréter comme une probabilité, qui doit vivre dans $[0, 1]$. De plus, la perte quadratique suppose implicitement un bruit gaussien sur la sortie, ce qui n'a pas de sens pour une variable binaire qui suit naturellement une loi de *Bernoulli*.

L'idée directrice

On garde un **score linéaire** $z = \mathbf{w}^\top \mathbf{x} + b \in \mathbb{R}$ (ce qu'on sait bien manipuler), puis on le **transforme en probabilité** via une fonction de liaison $g : \mathbb{R} \rightarrow (0, 1)$:

$$z = \mathbf{w}^\top \mathbf{x} + b \in \mathbb{R} \xrightarrow{g} p(\mathbf{x}) = g(z) \in (0, 1).$$

Toute la question est : *quelle fonction g choisir, et pourquoi ?* La réponse passe par la notion d'**odds**.

3 Les odds et le logit : l'origine de la sigmoïde

3.1 Qu'est-ce qu'une « cote » (odds) ?

Définition 3.1 (Cote / odds). Pour un événement de probabilité p , la **cote** (en anglais *odds*) est le rapport entre la probabilité que l'événement se produise et la probabilité qu'il ne se produise pas :

$$\text{odds} = \frac{p}{1-p}.$$

Comment lire une cote

Une cote, c'est la façon dont parlent les parieurs. Elle compare le « pour » au « contre » :

- $p = 0,5 \Rightarrow \text{odds} = \frac{0,5}{0,5} = 1$: une chance « pour » contre une chance « contre » (1 contre 1).
- $p = 0,75 \Rightarrow \text{odds} = \frac{0,75}{0,25} = 3$: l'événement est 3 fois plus probable que son contraire (3 contre 1).
- $p = 0,9 \Rightarrow \text{odds} = \frac{0,9}{0,1} = 9$ (9 contre 1).
- $p = 0,25 \Rightarrow \text{odds} = \frac{0,25}{0,75} = \frac{1}{3} \approx 0,33$ (1 contre 3).

La probabilité vit dans $[0, 1]$; la cote vit dans $[0, +\infty)$. On a « étiré » l'échelle vers le haut.

3.2 Le logit : passer de $(0, +\infty)$ à $\mathbb{R}$

La cote est positive mais bornée par 0 en bas. Pour obtenir une quantité qui parcourt *toute* la droite réelle $\mathbb{R}$ (exactement comme le score linéaire z), on prend le logarithme :

Définition 3.2 (Logit / log-odds). Le **logit** (ou *log-odds*) de p est le logarithme naturel de la cote :

$$\text{logit}(p) = \log(\text{odds}) = \log\left(\frac{p}{1-p}\right) \in \mathbb{R}.$$

Probabilité p	Cote $\frac{p}{1-p}$	Logit $\log \frac{p}{1-p}$	Interprétation
0,01	0,010	-4,60	très improbable
0,25	0,333	-1,10	improbable
0,50	1,000	0,00	équiprobable
0,75	3,000	+1,10	probable
0,99	99,00	+4,60	très probable

Intuition

Le logit est symétrique autour de $p = 0,5$ (où il vaut 0). Plus on s'approche de $p = 1$, plus il tend vers $+\infty$; plus on s'approche de $p = 0$, plus il tend vers $-\infty$. C'est *exactement* le bon domaine pour l'égaliser à un score linéaire $\mathbf{w}^T \mathbf{x} + b$, qui lui aussi parcourt tout $\mathbb{R}$.

3.3 Hypothèse fondamentale : un logit linéaire

La régression logistique fait une seule hypothèse de modélisation : le logit est une fonction **linéaire** des caractéristiques.

$$\log\left(\frac{p(\mathbf{x})}{1-p(\mathbf{x})}\right) = \mathbf{w}^T \mathbf{x} + b \quad (1)$$

3.4 Dérivation de la sigmoïde (calcul complet)

On résout (1) pour exprimer p en fonction de $z = \mathbf{w}^\top \mathbf{x} + b$. On part de

$$\log\left(\frac{p}{1-p}\right) = z.$$

On applique l'exponentielle des deux côtés, puis on isole p :

$$\begin{aligned}\frac{p}{1-p} &= e^z && \text{(exponentielle)} \\ p &= e^z (1-p) && \text{(produit en croix)} \\ p &= e^z - e^z p && \text{(distribution)} \\ p + e^z p &= e^z && \text{(on regroupe les } p) \\ p(1 + e^z) &= e^z && \text{(factorisation)} \\ p &= \frac{e^z}{1 + e^z} = \frac{1}{1 + e^{-z}} && \text{(on divise haut et bas par } e^z).\end{aligned}$$

On obtient la **fonction logistique** (ou *sigmoïde*) :

$$p(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b), \quad \sigma(z) = \frac{1}{1 + e^{-z}} \quad (2)$$

À retenir

La sigmoïde n'est pas choisie « par magie » : elle est la **conséquence mathématique** de l'hypothèse « le logit est linéaire ». C'est la fonction réciproque du logit.

3.5 Propriétés de la sigmoïde

Propriété 3.1 (Bornes et symétrie). Pour tout $z \in \mathbb{R}$: $0 < \sigma(z) < 1$, $\sigma(0) = \frac{1}{2}$, $\sigma(z) \rightarrow 1$ quand $z \rightarrow +\infty$, $\sigma(z) \rightarrow 0$ quand $z \rightarrow -\infty$, et la symétrie

$$\sigma(-z) = 1 - \sigma(z).$$

$$\text{Preuve de la symétrie : } \sigma(-z) = \frac{1}{1 + e^z} = \frac{e^{-z}}{e^{-z} + 1} = \frac{e^{-z}}{1 + e^{-z}} = 1 - \frac{1}{1 + e^{-z}} = 1 - \sigma(z).$$

3.6 Dérivée de la sigmoïde (calcul complet)

Cette dérivée est centrale pour les gradients. Écrivons $\sigma(z) = (1 + e^{-z})^{-1}$ et dérivons par la règle de chaîne :

$$\begin{aligned}\sigma'(z) &= -1 \cdot (1 + e^{-z})^{-2} \cdot \frac{d}{dz}(1 + e^{-z}) = -(1 + e^{-z})^{-2} \cdot (-e^{-z}) \\ &= \frac{e^{-z}}{(1 + e^{-z})^2}.\end{aligned}$$

On réécrit ce résultat en fonction de $\sigma(z)$. Comme $1 - \sigma(z) = \frac{e^{-z}}{1 + e^{-z}}$, on a

$$\sigma(z)(1 - \sigma(z)) = \frac{1}{1 + e^{-z}} \cdot \frac{e^{-z}}{1 + e^{-z}} = \frac{e^{-z}}{(1 + e^{-z})^2} = \sigma'(z).$$

D'où la relation remarquable :

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)) \quad (3)$$

4 Interprétation des coefficients : l'odds ratio

L'hypothèse du logit linéaire (1) donne une lecture concrète des poids w_j . Augmentons la j -ème caractéristique d'une unité, $x_j \rightarrow x_j + 1$, en gardant les autres fixées. Le logit augmente de w_j . En termes de cote :

$$\frac{\text{odds}(\mathbf{x} \text{ avec } x_j + 1)}{\text{odds}(\mathbf{x})} = \frac{e^{\mathbf{w}^T \mathbf{x} + b + w_j}}{e^{\mathbf{w}^T \mathbf{x} + b}} = e^{w_j}.$$

Odds ratio

La quantité e^{w_j} est l'**odds ratio** (rapport de cotes) associé à la caractéristique j :

- $w_j > 0 \Rightarrow e^{w_j} > 1$: augmenter x_j *multiplie* la cote $\Rightarrow$ pousse vers la classe 1.
- $w_j < 0 \Rightarrow e^{w_j} < 1$: augmenter x_j *divise* la cote $\Rightarrow$ pousse vers la classe 0.
- $w_j = 0 \Rightarrow e^{w_j} = 1$: la caractéristique j n'a aucun effet.

Exemple 4.1. Si $w_j = \log 2 \approx 0,693$, alors $e^{w_j} = 2$: chaque unité supplémentaire de x_j *double* la cote en faveur de la classe 1. C'est ce qui rend la régression logistique très appréciée en médecine et en économie : les coefficients sont directement interprétables.

5 La fonction de coût par maximum de vraisemblance (MLE)

5.1 Modèle probabiliste : Bernoulli conditionnelle

On suppose que, conditionnellement à $\mathbf{x}^{(i)}$, l'étiquette suit une loi de Bernoulli de paramètre $p^{(i)}$:

$$y^{(i)} \mid \mathbf{x}^{(i)} \sim \text{Bernoulli}(p^{(i)}), \quad p^{(i)} = \sigma(z^{(i)}), \quad z^{(i)} = \mathbf{w}^T \mathbf{x}^{(i)} + b.$$

La fonction de masse de probabilité (pmf) s'écrit de manière compacte :

$$\mathbb{P}(y^{(i)} \mid \mathbf{x}^{(i)}) = (p^{(i)})^{y^{(i)}} (1 - p^{(i)})^{1-y^{(i)}}.$$

Intuition

Cette écriture est une astuce : si $y^{(i)} = 1$, il reste $p^{(i)}$; si $y^{(i)} = 0$, il reste $1 - p^{(i)}$. L'exposant « allume » le bon terme.

5.2 Vraisemblance puis log-vraisemblance

Sous l'hypothèse d'indépendance conditionnelle des observations, la **vraisemblance** est le produit :

$$\mathcal{L}(\mathbf{w}, b) = \prod_{i=1}^m (p^{(i)})^{y^{(i)}} (1 - p^{(i)})^{1-y^{(i)}}.$$

Les produits de probabilités sont numériquement instables et difficiles à dériver ; on passe au logarithme (qui est croissant, donc préserve l'arg max) :

$$\ell(\mathbf{w}, b) = \log \mathcal{L}(\mathbf{w}, b) = \sum_{i=1}^m \left[y^{(i)} \log p^{(i)} + (1 - y^{(i)}) \log(1 - p^{(i)}) \right].$$

5.3 De la maximisation à la minimisation : l'entropie croisée

Maximiser ℓ revient à minimiser $-\ell$. On définit la fonction de coût (moyenne par m pour ne pas dépendre de la taille du jeu) :

$$J(\mathbf{w}, b) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log p^{(i)} + (1 - y^{(i)}) \log(1 - p^{(i)}) \right] \quad (4)$$

appelée **log-perte** ou **entropie croisée binaire** (binary cross-entropy), avec $p^{(i)} = \sigma(\mathbf{w}^\top \mathbf{x}^{(i)} + b)$.

Pourquoi pas la MSE ici ?

Avec la sigmoïde, la MSE $\frac{1}{2m} \sum (\sigma(z^{(i)}) - y^{(i)})^2$ donne une fonction *non convexe* en $(\mathbf{w}, b)$, pleine de minima locaux. L'entropie croisée, au contraire, est *convexe* (on le montre à la section 8), ce qui garantit un unique minimum global.

6 Gradients : dérivations pas à pas

Pour alléger les notations, on travaille sur *une* observation et on note

$$y = y^{(i)}, \quad \mathbf{x} = \mathbf{x}^{(i)}, \quad z = \mathbf{w}^\top \mathbf{x} + b, \quad p = \sigma(z).$$

La perte ponctuelle (sans moyenne) est

$$L(\mathbf{w}, b) = -[y \log p + (1 - y) \log(1 - p)].$$

6.1 Dérivée de L par rapport à z

On dérive terme à terme, en se rappelant que $p = \sigma(z)$ donc $\frac{dp}{dz} = \sigma'(z)$ et $\frac{d(1-p)}{dz} = -\frac{dp}{dz}$:

$$\frac{dL}{dz} = - \left[y \frac{1}{p} \frac{dp}{dz} + (1 - y) \frac{1}{1-p} \frac{d(1-p)}{dz} \right] = -\frac{dp}{dz} \left[\frac{y}{p} - \frac{1-y}{1-p} \right].$$

On met le crochet au même dénominateur :

$$\frac{y}{p} - \frac{1-y}{1-p} = \frac{y(1-p) - p(1-y)}{p(1-p)} = \frac{y - \cancel{yp} - p + \cancel{py}}{p(1-p)} = \frac{y-p}{p(1-p)}.$$

Donc

$$\frac{dL}{dz} = -\frac{dp}{dz} \cdot \frac{y-p}{p(1-p)}.$$

Or, par (3), $\frac{dp}{dz} = \sigma'(z) = p(1-p)$, qui se simplifie exactement avec le dénominateur :

$$\frac{dL}{dz} = -p(1-p) \cdot \frac{y-p}{p(1-p)} = -(y-p).$$

On obtient la relation fondamentale, d'une simplicité remarquable :

$$\boxed{\frac{dL}{dz} = p - y} \quad (5)$$

Intuition

Le gradient par rapport au score est juste l'**erreur de prédiction** $p - y$ (probabilité prédite moins vérité). Cette élégance vient du couplage entre la sigmoïde et l'entropie croisée : ce sont des « partenaires naturels ».

6.2 Gradient par rapport à $\mathbf{w}$

Comme $z = \mathbf{w}^\top \mathbf{x} + b$, on a $\frac{\partial z}{\partial \mathbf{w}} = \mathbf{x}$. Par la règle de chaîne :

$$\frac{\partial L}{\partial \mathbf{w}} = \frac{dL}{dz} \cdot \frac{\partial z}{\partial \mathbf{w}} = (p - y) \mathbf{x}.$$

En réintroduisant la moyenne sur les m exemples :

$$\nabla_{\mathbf{w}} J = \frac{1}{m} \sum_{i=1}^m (p^{(i)} - y^{(i)}) \mathbf{x}^{(i)}.$$

Sous forme matricielle, avec $\mathbf{X} \in \mathbb{R}^{m \times n}$ (matrice des exemples), $\mathbf{p} \in \mathbb{R}^m$ et $\mathbf{y} \in \mathbb{R}^m$:

$$\boxed{\nabla_{\mathbf{w}} J = \frac{1}{m} \mathbf{X}^\top (\mathbf{p} - \mathbf{y})} \quad (6)$$

6.3 Gradient par rapport à b

Comme $\frac{\partial z}{\partial b} = 1$, on a $\frac{\partial L}{\partial b} = (p - y) \cdot 1 = p - y$, d'où

$$\frac{\partial J}{\partial b} = \frac{1}{m} \sum_{i=1}^m (p^{(i)} - y^{(i)}). \quad (7)$$

7 Pourquoi pas de solution fermée ?

Les conditions d'optimalité (gradient nul) imposent

$$\nabla_{\mathbf{w}} J = \frac{1}{m} \mathbf{X}^\top (\mathbf{p} - \mathbf{y}) = \mathbf{0} \quad \text{et} \quad \frac{\partial J}{\partial b} = 0.$$

Mais $\mathbf{p} = \sigma(\mathbf{X}\mathbf{w} + b\mathbf{1})$ dépend de $\mathbf{w}$ de manière **non linéaire** (via l'exponentielle). Contrairement à la régression linéaire, qui mène au système linéaire des équations normales

$$\mathbf{X}^\top \mathbf{X} \mathbf{w} = \mathbf{X}^\top \mathbf{y} \implies \mathbf{w} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y},$$

ici on obtient le système **non linéaire**

$$\mathbf{X}^\top \sigma(\mathbf{X}\mathbf{w} + b\mathbf{1}) = \mathbf{X}^\top \mathbf{y},$$

qui n'admet pas de solution analytique en général. On doit donc recourir à des méthodes **numériques itératives**.

8 Hessienne et convexité

8.1 Calcul de la Hessienne

On part de $\nabla_{\mathbf{w}} J = \frac{1}{m} \mathbf{X}^\top (\mathbf{p} - \mathbf{y})$ avec $\mathbf{p} = \sigma(\mathbf{X}\mathbf{w} + b\mathbf{1})$. La dérivée de chaque composante p_i par rapport à son score z_i vaut $p_i(1 - p_i)$. On définit la matrice diagonale de *pondérations*

$$R = \text{diag}(p_1(1 - p_1), \dots, p_m(1 - p_m)) \in \mathbb{R}^{m \times m}.$$

Alors $\frac{\partial \mathbf{p}}{\partial \mathbf{w}} = R\mathbf{X}$ et la matrice hessienne est

$$\boxed{H = \nabla_{\mathbf{w}}^2 J = \frac{1}{m} \mathbf{X}^\top R \mathbf{X}} \quad (8)$$

8.2 La fonction de coût est convexe

Comme $0 < p_i < 1$, chaque terme diagonal vérifie $p_i(1 - p_i) > 0$, donc R est définie positive. Pour tout vecteur $\mathbf{v} \in \mathbb{R}^n$:

$$\mathbf{v}^\top H \mathbf{v} = \frac{1}{m} \mathbf{v}^\top \mathbf{X}^\top R \mathbf{X} \mathbf{v} = \frac{1}{m} (\mathbf{X} \mathbf{v})^\top R (\mathbf{X} \mathbf{v}) = \frac{1}{m} \sum_{i=1}^m p_i(1 - p_i) (\mathbf{X} \mathbf{v})_i^2 \geq 0.$$

Donc H est semi-définie positive : J est **convexe**. Si $\mathbf{X}$ est de rang plein, l'inégalité est stricte et J est *strictement convexe* : il existe un **unique minimum global**.

À retenir

Convexité $\Rightarrow$ pas de minima locaux parasites. C'est la raison profonde pour laquelle la descente de gradient « marche » fiablement en régression logistique.

9 Optimisation : descente de gradient et Newton / IRLS

9.1 Descente de gradient

On met à jour les paramètres dans la direction opposée au gradient, avec un pas (*learning rate*) $\alpha > 0$:

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \alpha \nabla_{\mathbf{w}} J(\mathbf{w}^{(t)}, b^{(t)}), \quad b^{(t+1)} = b^{(t)} - \alpha \frac{\partial J}{\partial b}(\mathbf{w}^{(t)}, b^{(t)}).$$

Simple, peu coûteux par itération, c'est la méthode par défaut pour les grands n .

9.2 Newton–Raphson / IRLS

La méthode de Newton utilise l'information de courbure (la Hessienne) :

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - H^{-1} \nabla_{\mathbf{w}} J.$$

En injectant (6) et (8) (le facteur $\frac{1}{m}$ se simplifie) :

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - (\mathbf{X}^\top R \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{p} - \mathbf{y}).$$

Cette itération est exactement une suite de **moindres carrés pondérés itérés** (IRLS, *Iteratively Reweighted Least Squares*), où les pondérations R changent à chaque étape. Newton converge en peu d'itérations (convergence quadratique), mais chaque étape coûte l'inversion d'une matrice $n \times n$.

10 Régularisation

10.1 Pourquoi régulariser ?

Deux problèmes motivent la régularisation :

1. **Surapprentissage (overfitting)**. Avec beaucoup de caractéristiques (grand n) ou peu de données, le modèle peut coller au bruit. Des poids $\mathbf{w}$ très grands rendent les prédictions extrêmes et fragiles.
2. **Séparation parfaite (divergence des poids)**. Si les classes sont linéairement séparables, le maximum de vraisemblance n'existe pas : l'algorithme pousse $\|\mathbf{w}\| \rightarrow \infty$ pour rendre les $p^{(i)}$ exactement 0 ou 1. Le coût (4) décroît sans jamais atteindre de minimum fini. La régularisation *borne* les poids et résout ce problème.

Principe

On ajoute au coût un **terme de pénalité** $\Omega(\mathbf{w})$ qui punit les grands poids :

$$J_{\text{reg}}(\mathbf{w}, b) = \underbrace{J(\mathbf{w}, b)}_{\text{ajustement}} + \lambda \underbrace{\Omega(\mathbf{w})}_{\text{pénalité}}.$$

Le paramètre $\lambda \geq 0$ contrôle le compromis : $\lambda = 0$ redonne le modèle non régularisé ; λ grand force des poids petits. **Remarque importante** : on ne pénalise généralement *pas* le biais b , car il ne fait que décaler le seuil et ne contrôle pas la complexité.

10.2 Régularisation L2 (Ridge)

La pénalité L2 (ou *ridge*, *weight decay*) utilise le carré de la norme euclidienne :

$$\Omega(\mathbf{w}) = \frac{1}{2} \|\mathbf{w}\|_2^2 = \frac{1}{2} \sum_{j=1}^n w_j^2, \quad J_{\text{reg}}(\mathbf{w}, b) = J(\mathbf{w}, b) + \frac{\lambda}{2} \sum_{j=1}^n w_j^2.$$

Effet sur le gradient. La dérivée de $\frac{\lambda}{2} \sum_j w_j^2$ par rapport à w_j vaut λw_j . Le gradient régularisé devient donc

$$\nabla_{\mathbf{w}} J_{\text{reg}} = \frac{1}{m} \mathbf{X}^T (\mathbf{p} - \mathbf{y}) + \lambda \mathbf{w}.$$

La mise à jour de descente de gradient s'écrit alors

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \alpha \left(\frac{1}{m} \mathbf{X}^T (\mathbf{p} - \mathbf{y}) + \lambda \mathbf{w}^{(t)} \right) = \underbrace{(1 - \alpha\lambda)}_{<1} \mathbf{w}^{(t)} - \frac{\alpha}{m} \mathbf{X}^T (\mathbf{p} - \mathbf{y}).$$

Intuition

Le facteur $(1 - \alpha\lambda) < 1$ « rétrécit » les poids à chaque itération avant la mise à jour : d'où le nom *weight decay* (décroissance des poids).

Effet sur la Hessienne. La Hessienne devient $H_{\text{reg}} = \frac{1}{m} \mathbf{X}^T R \mathbf{X} + \lambda I$. Le terme λI ($\lambda > 0$) rend H_{reg} *strictement* définie positive : le coût devient strictement convexe *même si* $\mathbf{X}$ n'est pas de rang plein. On garantit donc une solution unique et finie.

Interprétation bayésienne (MAP). La L2 équivaut à placer un *a priori* gaussien $\mathbf{w} \sim \mathcal{N}(0, \tau^2 I)$ sur les poids et à chercher le maximum a posteriori. En effet, $-\log$ de la densité gaussienne donne un terme proportionnel à $\|\mathbf{w}\|_2^2$ (avec $\lambda \propto 1/\tau^2$). Croire « a priori que les poids sont petits et proches de 0 » produit exactement la pénalité ridge.

10.3 Régularisation L1 (Lasso)

La pénalité L1 utilise la norme ℓ_1 (somme des valeurs absolues) :

$$\Omega(\mathbf{w}) = \|\mathbf{w}\|_1 = \sum_{j=1}^n |w_j|, \quad J_{\text{reg}}(\mathbf{w}, b) = J(\mathbf{w}, b) + \lambda \sum_{j=1}^n |w_j|.$$

Effet : la parcimonie (sparsité). La grande propriété de la L1 est qu'elle met *exactement* à zéro certains poids : elle réalise une **sélection de variables** automatique. Géométriquement, la « boule » ℓ_1 a des coins (sur les axes) ; le minimum contraint tend à tomber sur un coin, donc sur une solution où des $w_j = 0$.

Sous-gradient. La valeur absolue n'est pas dérivable en 0. On utilise le *sous-gradient* :

$$\frac{\partial}{\partial w_j} |w_j| = \begin{cases} +1 & \text{si } w_j > 0, \\ -1 & \text{si } w_j < 0, \\ [-1, 1] & \text{si } w_j = 0, \end{cases} \quad \text{noté } \text{sign}(w_j).$$

Le (sous-)gradient régularisé s'écrit $\nabla_{\mathbf{w}} J_{\text{reg}} = \frac{1}{m} \mathbf{X}^T (\mathbf{p} - \mathbf{y}) + \lambda \text{sign}(\mathbf{w})$. En pratique on utilise des solveurs dédiés (descente de coordonnées, opérateur de *soft-thresholding*, méthodes proximales).

Interprétation bayésienne (MAP). La L1 équivaut à un *a priori* de Laplace sur les poids : $-\log$ de la densité de Laplace est proportionnel à $|w_j|$. Cet *a priori* est plus « pointu » en 0 que la gaussienne, ce qui favorise les solutions parcimonieuses.

10.4 Elastic Net : combiner L1 et L2

On peut mélanger les deux pénalités pour cumuler la parcimonie de la L1 et la stabilité de la L2 (utile quand des caractéristiques sont fortement corrélées) :

$$J_{\text{reg}}(\mathbf{w}, b) = J(\mathbf{w}, b) + \lambda \left[\rho \|\mathbf{w}\|_1 + \frac{1-\rho}{2} \|\mathbf{w}\|_2^2 \right], \quad \rho \in [0, 1].$$

$\rho = 1$ redonne la L1 (Lasso), $\rho = 0$ redonne la L2 (Ridge).

10.5 L1 vs L2 : tableau récapitulatif

	L2 (Ridge)	L1 (Lasso)
Pénalité	$\frac{\lambda}{2} \sum_j w_j^2$	$\lambda \sum_j w_j $
A priori bayésien	Gaussien $\mathcal{N}(0, \tau^2)$	Laplace
Effet sur les poids	Les rétrécit (proches de 0)	En annule certains (exactement 0)
Parcimonie / sélection	Non	Oui
Dérivabilité	Partout (C^∞)	Non dérivable en 0 (sous-gradient)
Variables corrélées	Les garde toutes	En choisit une, ignore les autres

Convention de scikit-learn : le paramètre C

Dans `LogisticRegression`, on ne règle pas λ mais $C = \frac{1}{\lambda}$, l'**inverse** de la force de régularisation. Le coût minimisé est de la forme

$$\min_{\mathbf{w}, b} C \sum_{i=1}^m L^{(i)}(\mathbf{w}, b) + \Omega(\mathbf{w}).$$

Donc : C **petit** $\Rightarrow$ forte régularisation (poids très contraints) ; C **grand** $\Rightarrow$ faible régularisation. C'est l'opposé de λ : à ne pas confondre.

11 Récapitulatif : la chaîne complète

1. **Régression linéaire** : $\hat{y} = \mathbf{w}^T \mathbf{x} + b$, sortie dans $\mathbb{R} \Rightarrow$ inadaptée à une probabilité.

2. **Odds et logit** : on définit $\text{odds} = \frac{p}{1-p} \in (0, \infty)$, puis $\text{logit}(p) = \log \frac{p}{1-p} \in \mathbb{R}$.
 3. **Hypothèse** : le logit est linéaire, $\log \frac{p}{1-p} = \mathbf{w}^\top \mathbf{x} + b$.
 4. **Conséquence** : la probabilité est donnée par la sigmoïde, $p = \sigma(\mathbf{w}^\top \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^\top \mathbf{x} + b)}}$.
 5. **Interprétation** : e^{w_j} est l'odds ratio de la caractéristique j .
 6. **Apprentissage (MLE)** : on minimise l'entropie croisée $J = -\frac{1}{m} \sum_i [y^{(i)} \log p^{(i)} + (1 - y^{(i)}) \log(1 - p^{(i)})]$.
 7. **Gradients** : relation clé $\frac{dL}{dz} = p - y$, d'où $\nabla_{\mathbf{w}} J = \frac{1}{m} \mathbf{X}^\top (\mathbf{p} - \mathbf{y})$.
 8. **Pas de solution fermée** : le système est non linéaire $\Rightarrow$ méthodes itératives (GD, Newton/IRLS).
 9. **Convexité** : $H = \frac{1}{m} \mathbf{X}^\top R \mathbf{X} \succeq 0$, donc un minimum global.
 10. **Régularisation** : on ajoute $\lambda \Omega(\mathbf{w})$; L2 rétrécit les poids (a priori gaussien), L1 crée de la parcimonie (a priori de Laplace), Elastic Net combine les deux. Dans scikit-learn, on règle $C = 1/\lambda$.
-