

La régression linéaire

Des moindres carrés à la régularisation,
avec démonstrations détaillées et interprétations

5 juin 2026

Table des matières

1	Le problème : ajuster une relation linéaire	1
2	Cas scalaire : la droite des moindres carrés	2
2.1	Résidu et fonction de coût	2
2.2	Conditions d'optimalité (calcul détaillé)	2
2.3	Équations normales	2
2.4	Solution explicite (dérivation)	3
3	Cas multivarié : la forme matricielle	3
3.1	Modèle	3
3.2	Fonction de coût matricielle	3
3.3	Développement (calcul détaillé)	3
3.4	Gradient et équations normales	4
3.5	Solution des moindres carrés	4
4	Interprétation géométrique : la projection orthogonale	4
5	Cas où $X^T X$ n'est pas inversible	4
6	Interprétation probabiliste : MCO = maximum de vraisemblance	5
7	Le compromis biais-variance (motivation de la régularisation)	5
8	Régularisation	6
8.1	Principe	6
8.2	Régularisation L2 (Ridge)	6
8.3	Régularisation L1 (Lasso)	6
8.4	Elastic Net : combiner L1 et L2	7
8.5	Tableau récapitulatif	7
8.6	Impact sur la généralisation	7
9	Récapitulatif : la chaîne complète	8

1 Le problème : ajuster une relation linéaire

On dispose d'un jeu de données supervisé de n exemples :

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n), \quad x_i \in \mathbb{R} \text{ (ou } \mathbb{R}^p), y_i \in \mathbb{R}.$$

La **régression** cherche à expliquer la sortie continue y (la *variable à expliquer*, ou *réponse*) en fonction des entrées x (les *variables explicatives*, ou *features*). Dans le cas le plus simple, on postule une relation **affine** :

$$y \approx ax + b.$$

Intuition

En général, aucune droite ne passe *exactement* par tous les points (il y a du bruit, des mesures imparfaites). On ne cherche donc pas la droite « parfaite », mais celle qui **approxime au mieux** le nuage. Reste à définir « au mieux » : c'est le rôle de la *fonction de coût*.

2 Cas scalaire : la droite des moindres carrés

2.1 Résidu et fonction de coût

Pour chaque point i , on définit le **résidu** : l'écart vertical entre la valeur observée et la valeur prédite par la droite,

$$e_i = y_i - (ax_i + b).$$

La méthode des **moindres carrés** (MCO, ou OLS en anglais) consiste à choisir (a, b) qui minimisent la **somme des carrés des résidus** :

$$S(a, b) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - ax_i - b)^2. \quad (1)$$

Pourquoi le carré ?

On élève au carré pour deux raisons : (i) les écarts positifs et négatifs ne se compensent pas (sinon une mauvaise droite pourrait avoir une somme de résidus nulle) ; (ii) le carré est dérivable partout, ce qui donne une solution analytique simple. Il pénalise aussi fortement les gros écarts (sensibilité aux valeurs aberrantes, c'est le revers).

2.2 Conditions d'optimalité (calcul détaillé)

S est une fonction convexe de (a, b) (somme de paraboles). Son minimum est atteint là où les deux dérivées partielles s'annulent.

Dérivée par rapport à a . En dérivant (1) terme à terme (règle de chaîne, la dérivée interne de $(y_i - ax_i - b)$ par rapport à a est $-x_i$) :

$$\frac{\partial S}{\partial a} = \sum_{i=1}^n 2(y_i - ax_i - b)(-x_i) = 0 \implies \sum_{i=1}^n x_i (y_i - ax_i - b) = 0.$$

Dérivée par rapport à b . De même (dérivée interne -1) :

$$\frac{\partial S}{\partial b} = \sum_{i=1}^n 2(y_i - ax_i - b)(-1) = 0 \implies \sum_{i=1}^n (y_i - ax_i - b) = 0.$$

2.3 Équations normales

En développant ces deux conditions, on obtient le système linéaire (les **équations normales**) :

$$\begin{cases} a \sum_i x_i^2 + b \sum_i x_i = \sum_i x_i y_i, \\ a \sum_i x_i + n b = \sum_i y_i. \end{cases} \quad (2)$$

2.4 Solution explicite (dérivation)

De la deuxième équation, en divisant par n et avec les moyennes $\bar{x} = \frac{1}{n} \sum_i x_i$, $\bar{y} = \frac{1}{n} \sum_i y_i$:

$$b = \bar{y} - a\bar{x}.$$

On injecte dans la première équation :

$$a \sum_i x_i^2 + (\bar{y} - a\bar{x}) \sum_i x_i = \sum_i x_i y_i \implies a \left(\sum_i x_i^2 - \bar{x} \sum_i x_i \right) = \sum_i x_i y_i - \bar{y} \sum_i x_i.$$

En utilisant $\sum_i x_i = n\bar{x}$ et $\sum_i y_i = n\bar{y}$:

$$a = \frac{\sum_i x_i y_i - n\bar{x}\bar{y}}{\sum_i x_i^2 - n\bar{x}^2} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} = \frac{\text{Cov}(x, y)}{\text{Var}(x)}, \quad b = \bar{y} - a\bar{x}. \quad (3)$$

À retenir

La pente est le rapport « covariance sur variance ». L'ordonnée à l'origine $b = \bar{y} - a\bar{x}$ garantit que la droite passe par le **centre de gravité** $(\bar{x}, \bar{y})$ du nuage de points.

3 Cas multivarié : la forme matricielle

3.1 Modèle

Avec p variables explicatives, le modèle linéaire s'écrit pour chaque exemple $\hat{y}_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij}$. En empilant les n exemples, on adopte la notation matricielle :

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad (4)$$

où

- $\mathbf{Y} \in \mathbb{R}^n$ est le vecteur des observations ;
- $\mathbf{X} \in \mathbb{R}^{n \times p}$ est la **matrice de design** (une ligne par exemple, une colonne par variable ; on ajoute usuellement une colonne de 1 pour le biais) ;
- $\boldsymbol{\beta} \in \mathbb{R}^p$ est le vecteur des paramètres à estimer ;
- $\boldsymbol{\varepsilon} \in \mathbb{R}^n$ est le bruit (les erreurs).

3.2 Fonction de coût matricielle

On minimise la norme euclidienne au carré du résidu :

$$J(\boldsymbol{\beta}) = \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 = (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}).$$

3.3 Développement (calcul détaillé)

On développe le produit :

$$J(\boldsymbol{\beta}) = \mathbf{Y}^\top \mathbf{Y} - \mathbf{Y}^\top \mathbf{X}\boldsymbol{\beta} - \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{Y} + \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{X}\boldsymbol{\beta}.$$

Le terme $\mathbf{Y}^\top \mathbf{X}\boldsymbol{\beta}$ est un **scalaire** ; il est donc égal à sa transposée : $\mathbf{Y}^\top \mathbf{X}\boldsymbol{\beta} = (\mathbf{Y}^\top \mathbf{X}\boldsymbol{\beta})^\top = \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{Y}$. Les deux termes croisés se regroupent :

$$J(\boldsymbol{\beta}) = \mathbf{Y}^\top \mathbf{Y} - 2\boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{Y} + \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{X}\boldsymbol{\beta}. \quad (5)$$

3.4 Gradient et équations normales

Identités de calcul matriciel

Pour un vecteur constant $\mathbf{a}$ et une matrice symétrique $\mathbf{A}$:

$$\nabla_{\beta}(\beta^T \mathbf{a}) = \mathbf{a}, \quad \nabla_{\beta}(\beta^T \mathbf{A} \beta) = 2 \mathbf{A} \beta.$$

La matrice $\mathbf{X}^T \mathbf{X}$ est symétrique (car $(\mathbf{X}^T \mathbf{X})^T = \mathbf{X}^T \mathbf{X}$). En appliquant ces identités à (5) :

$$\nabla_{\beta} J(\beta) = -2 \mathbf{X}^T \mathbf{Y} + 2 \mathbf{X}^T \mathbf{X} \beta.$$

La condition d'optimalité $\nabla_{\beta} J = \mathbf{0}$ donne les **équations normales** :

$$\boxed{\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T \mathbf{Y}} \quad (6)$$

3.5 Solution des moindres carrés

Si $\mathbf{X}^T \mathbf{X}$ est **inversible** (ce qui suppose $\mathbf{X}$ de rang plein en colonnes, donc $n \geq p$ et pas de colinéarité parfaite) :

$$\boxed{\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}} \quad (7)$$

Contrairement à la régression logistique, la régression linéaire possède donc une **solution fermée** (analytique).

4 Interprétation géométrique : la projection orthogonale

Les colonnes de $\mathbf{X}$ engendrent un sous-espace de $\mathbb{R}^n$, l'*espace des colonnes* $\text{Col}(\mathbf{X})$. On cherche le vecteur $\hat{\mathbf{Y}} = \mathbf{X} \hat{\beta}$ dans ce sous-espace qui soit le plus proche (au sens euclidien) de $\mathbf{Y}$.

Propriété 4.1 (Le résidu est orthogonal). La condition optimale (6) se réécrit

$$\mathbf{X}^T (\mathbf{Y} - \mathbf{X} \hat{\beta}) = \mathbf{0},$$

c'est-à-dire que le résidu $\hat{\mathbf{r}} = \mathbf{Y} - \mathbf{X} \hat{\beta}$ est **orthogonal** à toutes les colonnes de $\mathbf{X}$.

Intuition

Géométriquement, $\hat{\mathbf{Y}} = \mathbf{X} \hat{\beta}$ est la **projection orthogonale** de $\mathbf{Y}$ sur $\text{Col}(\mathbf{X})$. La meilleure approximation est celle dont l'erreur est perpendiculaire au sous-espace : on ne peut plus « descendre » le long de $\text{Col}(\mathbf{X})$ pour se rapprocher de $\mathbf{Y}$.

On peut écrire $\hat{\mathbf{Y}} = \mathbf{H} \mathbf{Y}$ avec la **matrice chapeau** (*hat matrix*)

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T,$$

qui est la matrice de projection orthogonale sur $\text{Col}(\mathbf{X})$ (elle vérifie $\mathbf{H} = \mathbf{H}^T$ et $\mathbf{H}^2 = \mathbf{H}$).

5 Cas où $\mathbf{X}^T \mathbf{X}$ n'est pas inversible

Si $\mathbf{X}^T \mathbf{X}$ n'est pas inversible, c'est que les colonnes de $\mathbf{X}$ sont **linéairement dépendantes** (colinéarité parfaite, ou plus de variables que d'exemples, $p > n$). Il existe alors une **infinité** de solutions aux équations normales. On utilise la **pseudo-inverse de Moore–Penrose** :

$$\hat{\beta} = \mathbf{X}^+ \mathbf{Y},$$

calculée numériquement via la **décomposition en valeurs singulières** (SVD). Parmi toutes les solutions, $\mathbf{X}^+\mathbf{Y}$ est celle de **norme minimale**.

Intuition

Quand $\mathbf{X}^T\mathbf{X}$ est « presque » singulière (variables très corrélées), son inverse contient des nombres énormes : les coefficients $\boldsymbol{\beta}$ deviennent gigantesques et instables (une petite variation des données fait exploser la solution). C'est exactement la situation que la **régularisation** (section 8) va corriger.

6 Interprétation probabiliste : MCO = maximum de vraisemblance

D'où vient le *carré* des résidus ? D'une hypothèse probabiliste précise. Supposons un **bruit gaussien** indépendant et de même variance :

$$y_i = \mathbf{x}_i^T \boldsymbol{\beta} + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2) \text{ i.i.d.}$$

Alors $y_i \mid \mathbf{x}_i \sim \mathcal{N}(\mathbf{x}_i^T \boldsymbol{\beta}, \sigma^2)$, de densité

$$p(y_i \mid \mathbf{x}_i) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \mathbf{x}_i^T \boldsymbol{\beta})^2}{2\sigma^2}\right).$$

La log-vraisemblance des n observations indépendantes vaut

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^n \log p(y_i \mid \mathbf{x}_i) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mathbf{x}_i^T \boldsymbol{\beta})^2.$$

Le premier terme ne dépend pas de $\boldsymbol{\beta}$. Maximiser ℓ par rapport à $\boldsymbol{\beta}$ revient donc exactement à **minimiser** $\sum_i (y_i - \mathbf{x}_i^T \boldsymbol{\beta})^2$, c'est-à-dire le critère des moindres carrés :

$$\arg \max_{\boldsymbol{\beta}} \ell(\boldsymbol{\beta}) = \arg \min_{\boldsymbol{\beta}} \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 = \hat{\boldsymbol{\beta}}_{\text{MCO}} \quad (8)$$

À retenir

Les moindres carrés ne sont pas un choix arbitraire : ils sont l'estimateur du maximum de vraisemblance **lorsque le bruit est gaussien**. C'est l'analogue, pour la régression linéaire, de la dérivation « Bernoulli $\Rightarrow$ entropie croisée » de la régression logistique.

7 Le compromis biais–variance (motivation de la régularisation)

Pour une nouvelle entrée $\mathbf{x}_0$, l'erreur de prédiction quadratique attendue d'un estimateur $\hat{f}(\mathbf{x}_0)$ se décompose en trois termes :

$$\mathbb{E}[(y_0 - \hat{f}(\mathbf{x}_0))^2] = \underbrace{(\mathbb{E}[\hat{f}(\mathbf{x}_0)] - f(\mathbf{x}_0))^2}_{\text{Biais}^2} + \underbrace{\text{Var}(\hat{f}(\mathbf{x}_0))}_{\text{Variance}} + \underbrace{\sigma^2}_{\text{bruit irréductible}}.$$

Intuition

- Le **biais** mesure l'erreur systématique du modèle (trop simple, il rate la vraie relation : *sous-apprentissage*).
- La **variance** mesure la sensibilité du modèle aux fluctuations du jeu d'entraînement (trop complexe, il colle au bruit : *sur-apprentissage*).

Le MCO est « sans biais » mais peut avoir une **variance énorme** en présence de colinéarité. La régularisation accepte un *petit* biais en échange d'une *forte* réduction de variance : souvent, l'erreur totale *diminue*.

8 Régularisation

8.1 Principe

On ajoute au coût une **pénalité** $\Omega(\mathbf{w})$ sur les coefficients, contrôlée par un hyperparamètre $\lambda \geq 0$:

$$\min_{\mathbf{w}} \underbrace{\frac{1}{n} \|\mathbf{Y} - \mathbf{X}\mathbf{w}\|_2^2}_{\text{ajustement (MSE)}} + \lambda \underbrace{\Omega(\mathbf{w})}_{\text{pénalité}}.$$

$\lambda = 0$ redonne le MCO ; λ grand force des coefficients petits. Comme pour la logistique, on ne pénalise généralement *pas* l'intercept w_0 . On suppose les variables **standardisées** (même échelle), sinon la pénalité serait injuste entre variables.

8.2 Régularisation L2 (Ridge)

Formulation.

$$\min_{\mathbf{w}} \frac{1}{n} \|\mathbf{Y} - \mathbf{X}\mathbf{w}\|_2^2 + \lambda \|\mathbf{w}\|_2^2, \quad \|\mathbf{w}\|_2^2 = \sum_{j=1}^p w_j^2.$$

Solution fermée (dérivation complète). Travaillons avec le critère $\|\mathbf{Y} - \mathbf{X}\mathbf{w}\|_2^2 + \lambda \|\mathbf{w}\|_2^2$ (le $\frac{1}{n}$ se réabsorbe dans λ). Le gradient est

$$\nabla_{\mathbf{w}} \left[\|\mathbf{Y} - \mathbf{X}\mathbf{w}\|_2^2 + \lambda \|\mathbf{w}\|_2^2 \right] = -2\mathbf{X}^T \mathbf{Y} + 2\mathbf{X}^T \mathbf{X} \mathbf{w} + 2\lambda \mathbf{w}.$$

On annule :

$$\mathbf{X}^T \mathbf{X} \mathbf{w} + \lambda \mathbf{w} = \mathbf{X}^T \mathbf{Y} \implies (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}) \mathbf{w} = \mathbf{X}^T \mathbf{Y},$$

d'où la solution Ridge :

$$\hat{\mathbf{w}}_{\text{ridge}} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{Y} \quad (9)$$

Pourquoi ça stabilise (valeurs propres). $\mathbf{X}^T \mathbf{X}$ est semi-définie positive : ses valeurs propres $d_j^2 \geq 0$. En ajoutant $\lambda \mathbf{I}$, toutes les valeurs propres deviennent $d_j^2 + \lambda \geq \lambda > 0$. La matrice est donc **toujours inversible** (même si $\mathbf{X}^T \mathbf{X}$ ne l'était pas, même si $p > n$), et son *conditionnement* s'améliore : finis les coefficients qui explosent. Via la SVD, on montre que chaque composante est « rétrécie » d'un facteur $\frac{d_j^2}{d_j^2 + \lambda} < 1$: c'est un **rétrécissement continu** (shrinkage) de tous les coefficients vers 0, sans jamais les annuler.

Interprétation bayésienne (MAP). Ridge équivaut à placer un *a priori* gaussien $\mathbf{w} \sim \mathcal{N}(0, \tau^2 \mathbf{I})$ et à chercher le maximum a posteriori : $-\log$ de la densité gaussienne ajoute un terme $\propto \|\mathbf{w}\|_2^2$, avec $\lambda \propto 1/\tau^2$. Croire « les coefficients sont petits » produit la pénalité L2.

8.3 Régularisation L1 (Lasso)

Formulation.

$$\min_{\mathbf{w}} \frac{1}{n} \|\mathbf{Y} - \mathbf{X}\mathbf{w}\|_2^2 + \lambda \sum_{j=1}^p |w_j|.$$

Effet : la parcimonie (sparsité). Le Lasso met **exactement à zéro** certains coefficients : il réalise une **sélection automatique de variables**. Géométriquement, la région de contrainte $\|\mathbf{w}\|_1 \leq t$ est un « losange » (avec des coins sur les axes) ; les lignes de niveau de l'erreur touchent typiquement la contrainte sur un coin, là où des coordonnées sont nulles.

Pas de solution fermée, mais le soft-thresholding. $|w_j|$ n'est pas dérivable en 0 ; on utilise le *sous-gradient* $\text{sign}(w_j)$. Il n'y a pas de formule fermée générale. **Cas particulier instructif :** si les colonnes sont orthonormées ($\mathbf{X}^\top \mathbf{X} = \mathbf{I}$), avec le critère $\frac{1}{2} \|\mathbf{Y} - \mathbf{X}\mathbf{w}\|_2^2 + \lambda \|\mathbf{w}\|_1$, le minimum se calcule coordonnée par coordonnée et donne l'**opérateur de seuillage doux** :

$$\hat{w}_j^{\text{lasso}} = \text{sign}(\hat{w}_j^{\text{MCO}}) (|\hat{w}_j^{\text{MCO}}| - \lambda)_+, \quad (u)_+ = \max(u, 0).$$

Autrement dit : on *soustrait* λ à la magnitude de chaque coefficient MCO, et tout ce qui tombe sous le seuil est **remis exactement à 0**. C'est le mécanisme mathématique de la sparsité.

L1 vs L2, en une phrase

La L2 *rétrécit proportionnellement* (multiplie par un facteur < 1 , donc jamais zéro) ; la L1 *soustrait une constante* (donc peut atteindre zéro).

Interprétation bayésienne (MAP). Le Lasso correspond à un *a priori* de Laplace sur les coefficients ($-\log \text{densité} \propto |w_j|$), plus « pointu » en 0 que la gaussienne, ce qui favorise les solutions parcimonieuses.

8.4 Elastic Net : combiner L1 et L2

$$\min_{\mathbf{w}} \frac{1}{n} \|\mathbf{Y} - \mathbf{X}\mathbf{w}\|_2^2 + \lambda \left(\alpha \|\mathbf{w}\|_1 + (1 - \alpha) \|\mathbf{w}\|_2^2 \right), \quad \alpha \in [0, 1].$$

$\alpha = 1$ redonne le Lasso, $\alpha = 0$ redonne Ridge. L'Elastic Net combine la **sélection de variables** (L1) et la **stabilité numérique** (L2). Il est particulièrement adapté quand des variables sont **fortement corrélées** : là où le Lasso seul choisirait arbitrairement une seule variable d'un groupe corrélé, l'Elastic Net tend à les conserver ensemble.

8.5 Tableau récapitulatif

Méthode	But principal	Effet sur les coeff.	Variables corrélées
L2 (Ridge)	Réduire la variance	Rétrécis ($\neq 0$)	Très bon (les garde)
L1 (Lasso)	Sélectionner des variables	Beaucoup nuls (sparse)	Faible (en choisit une)
Elastic Net	Compromis	Zéros + stabilité	Bon (garde les groupes)

8.6 Impact sur la généralisation

- **Sans régularisation** : biais faible mais variance potentiellement élevée.
- **L2** : légère hausse du biais, forte baisse de la variance $\Rightarrow$ souvent meilleure prédiction.
- **L1** : modèle simple et interprétable, mais légèrement plus biaisé.
- **Elastic Net** : équilibre biais/variance souvent optimal en pratique.

Conventions des bibliothèques

Dans `scikit-learn`, Ridge et Lasso utilisent un paramètre **alpha** qui joue le rôle de λ (force de régularisation : grand **alpha** = forte pénalité). Attention : ce **alpha** n'a aucun rapport avec le **learning rate** de la descente de gradient, ni avec le paramètre $C = 1/\lambda$ de la `LogisticRegression`.

9 Récapitulatif : la chaîne complète

1. **Modèle** : relation linéaire $\hat{y} = ax + b$ (scalaire) ou $\hat{\mathbf{Y}} = \mathbf{X}\boldsymbol{\beta}$ (matriciel).
 2. **Critère** : minimiser la somme des carrés des résidus $S = \sum_i (y_i - \hat{y}_i)^2$.
 3. **Cas scalaire** : $a = \text{Cov}(x, y) / \text{Var}(x)$, $b = \bar{y} - a\bar{x}$.
 4. **Cas matriciel** : équations normales $\mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^\top \mathbf{Y}$, solution fermée $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$.
 5. **Géométrie** : $\mathbf{X}\hat{\boldsymbol{\beta}}$ est la projection orthogonale de $\mathbf{Y}$; le résidu est orthogonal aux colonnes de $\mathbf{X}$.
 6. **Cas singulier** : pseudo-inverse de Moore–Penrose via SVD ($\hat{\boldsymbol{\beta}} = \mathbf{X}^+ \mathbf{Y}$, norme minimale).
 7. **Probabiliste** : le MCO est le maximum de vraisemblance sous bruit gaussien.
 8. **Biais–variance** : le MCO peut avoir une grande variance $\Rightarrow$ motivation de la régularisation.
 9. **Ridge (L2)** : $\hat{\mathbf{w}} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{Y}$; rétrécit les coefficients, stabilise, a priori gaussien.
 10. **Lasso (L1)** : crée de la parcimonie (soft-thresholding), a priori de Laplace ; pas de solution fermée.
 11. **Elastic Net** : combine L1 (sélection) et L2 (stabilité).
-