

# Méthode des moindres carrés

## Présentation, démonstration et forme matricielle

### 1 Introduction

La méthode des moindres carrés est une technique mathématique permettant d'estimer les paramètres d'un modèle en minimisant l'erreur entre les valeurs observées et les valeurs prédites par le modèle.

### 2 Problème fondamental

On considère un ensemble de données expérimentales :

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

On cherche à approximer ces données par une fonction linéaire :

$$y = ax + b$$

En général, il n'existe pas de droite passant exactement par tous les points. On cherche donc la droite qui **approxime au mieux** les données.

### 3 Principe de la méthode des moindres carrés

Pour chaque point  $i$ , on définit le résidu :

$$e_i = y_i - (ax_i + b)$$

La méthode des moindres carrés consiste à minimiser :

$$S(a, b) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - ax_i - b)^2$$

### 4 Démonstration (cas scalaire)

On cherche :

$$\frac{\partial S}{\partial a} = 0 \quad \text{et} \quad \frac{\partial S}{\partial b} = 0$$

#### 4.1 Dérivée par rapport à $a$

$$\frac{\partial S}{\partial a} = \sum_{i=1}^n 2(y_i - ax_i - b)(-x_i)$$

Condition d'optimalité :

$$\sum_{i=1}^n x_i(y_i - ax_i - b) = 0$$

## 4.2 Dérivée par rapport à $b$

$$\frac{\partial S}{\partial b} = \sum_{i=1}^n 2(y_i - ax_i - b)(-1)$$

Condition d'optimalité :

$$\sum_{i=1}^n (y_i - ax_i - b) = 0$$

## 5 Équations normales

On obtient le système :

$$\begin{cases} a \sum x_i^2 + b \sum x_i = \sum x_i y_i \\ a \sum x_i + nb = \sum y_i \end{cases}$$

## 6 Solution explicite

$$a = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2}$$

$$b = \bar{y} - a\bar{x}$$

avec :

$$\bar{x} = \frac{1}{n} \sum x_i, \quad \bar{y} = \frac{1}{n} \sum y_i$$

## 7 Forme matricielle du problème

### 7.1 Modèle

$$Y = X\beta + \varepsilon$$

où :

- $Y \in \mathbb{R}^n$  est le vecteur des observations
- $X \in \mathbb{R}^{n \times p}$  est la matrice des variables explicatives
- $\beta \in \mathbb{R}^p$  est le vecteur des paramètres
- $\varepsilon$  est le bruit

## 8 Fonction coût matricielle

$$J(\beta) = \|Y - X\beta\|^2$$

Soit :

$$J(\beta) = (Y - X\beta)^T (Y - X\beta)$$

## 9 Démonstration matricielle

$$J(\beta) = Y^T Y - 2\beta^T X^T Y + \beta^T X^T X \beta$$

## 10 Calcul du gradient

On utilise les identités :

—  $\nabla_{\beta}(\beta^T a) = a$

—  $\nabla_{\beta}(\beta^T A \beta) = 2A\beta$  si  $A$  est symétrique

Comme  $X^T X$  est symétrique :

$$\nabla_{\beta} J(\beta) = -2X^T Y + 2X^T X \beta$$

Condition d'optimalité :

$$\nabla_{\beta} J(\beta) = 0$$

Donc :

$$X^T X \beta = X^T Y$$

## 11 Solution des moindres carrés

Si  $X^T X$  est inversible :

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

## 12 Interprétation géométrique

—  $X\hat{\beta}$  est la projection orthogonale de  $Y$  sur l'espace engendré par les colonnes de  $X$

— Le résidu  $\hat{r} = Y - X\hat{\beta}$  est orthogonal à cet espace :

$$X^T (Y - X\hat{\beta}) = 0$$

## 13 Cas général : matrice non inversible

Si  $X^T X$  n'est pas inversible :

— les colonnes de  $X$  sont linéairement dépendantes

— il existe une infinité de solutions

On utilise alors la **pseudo-inverse de Moore–Penrose** :

$$\hat{\beta} = X^+ Y$$

Calculée via la décomposition en valeurs singulières (SVD).

## 14 Conclusion

La méthode des moindres carrés :

— fournit une solution optimale au sens quadratique

— possède une interprétation géométrique claire

— est la base de la régression linéaire moderne

Elle s'étend naturellement aux modèles non linéaires et probabilistes.