

# Les machines à vecteurs de support (SVM)

Marge maximale, dualité, noyaux et régression — avec démonstrations

5 juin 2026

---

## Table des matières

|          |                                                               |          |
|----------|---------------------------------------------------------------|----------|
| <b>1</b> | <b>Cadre général</b>                                          | <b>1</b> |
| <b>2</b> | <b>Classification : la marge maximale</b>                     | <b>2</b> |
| 2.1      | Hyperplan et distance signée . . . . .                        | 2        |
| 2.2      | Marge fonctionnelle et géométrie . . . . .                    | 2        |
| 2.3      | Normalisation canonique . . . . .                             | 2        |
| 2.4      | SVM linéaire à marge dure . . . . .                           | 3        |
| 2.5      | SVM à marge souple . . . . .                                  | 3        |
| 2.6      | Équivalence avec la hinge loss . . . . .                      | 3        |
| <b>3</b> | <b>Dualité : dérivation complète</b>                          | <b>3</b> |
| 3.1      | Le Lagrangien . . . . .                                       | 3        |
| 3.2      | Conditions de stationnarité . . . . .                         | 4        |
| 3.3      | Substitution : le problème dual . . . . .                     | 4        |
| 3.4      | Fonction de décision et vecteurs de support . . . . .         | 4        |
| 3.5      | Conditions KKT : qui sont les vecteurs de support ? . . . . . | 4        |
| 3.6      | Récupération du biais $b$ . . . . .                           | 5        |
| <b>4</b> | <b>Noyaux (kernels)</b>                                       | <b>5</b> |
| 4.1      | Définition et kernel trick . . . . .                          | 5        |
| 4.2      | Condition de Mercer . . . . .                                 | 5        |
| 4.3      | Exemples . . . . .                                            | 5        |
| <b>5</b> | <b>Régression : Support Vector Regression (SVR)</b>           | <b>6</b> |
| 5.1      | Principe : le tube $\varepsilon$ -insensible . . . . .        | 6        |
| 5.2      | Problème primal . . . . .                                     | 6        |
| 5.3      | Dual et fonction de régression . . . . .                      | 6        |
| <b>6</b> | <b>Limites des SVM</b>                                        | <b>6</b> |
| <b>7</b> | <b>Synthèse</b>                                               | <b>6</b> |

---

## 1 Cadre général

On dispose d'un échantillon supervisé  $\{(\mathbf{x}_i, y_i)\}_{i=1}^m$ ,  $\mathbf{x}_i \in \mathbb{R}^d$ , avec

$$y_i \in \{-1, +1\} \text{ (classification) ou } y_i \in \mathbb{R} \text{ (régression)}.$$

Le modèle SVM général s'écrit

$$f(\mathbf{x}) = \mathbf{w}^\top \varphi(\mathbf{x}) + b,$$

où  $\varphi$  est une transformation vers un **espace de caractéristiques**,  $\mathbf{w}$  le vecteur de poids et  $b$  le biais.

### Le principe directeur

Les SVM **contrôlent la complexité** du modèle via la norme  $\|\mathbf{w}\|$  tout en assurant un bon ajustement. En classification, cela se traduit par la recherche de la **marge maximale** : on ne veut pas n'importe quel séparateur, mais celui qui laisse le plus grand « couloir » vide entre les classes.

## 2 Classification : la marge maximale

### 2.1 Hyperplan et distance signée

Un hyperplan de  $\mathbb{R}^d$  est  $H = \{\mathbf{x} \mid \mathbf{w}^\top \mathbf{x} + b = 0\}$ . La **distance signée** d'un point à  $H$  est

$$d(\mathbf{x}, H) = \frac{\mathbf{w}^\top \mathbf{x} + b}{\|\mathbf{w}\|}.$$

### 2.2 Marge fonctionnelle et géométrique

La **marge fonctionnelle** d'un point est  $\gamma_i = y_i(\mathbf{w}^\top \mathbf{x}_i + b)$  (positive si bien classé). La **marge géométrique** (distance réelle, signée par la classe) est

$$\hat{\gamma}_i = \frac{y_i(\mathbf{w}^\top \mathbf{x}_i + b)}{\|\mathbf{w}\|}, \quad \hat{\gamma} = \min_i \hat{\gamma}_i.$$

### 2.3 Normalisation canonique

$\mathbf{w}$  et  $b$  sont définis à une échelle près. On fixe cette échelle en imposant

$$\min_i y_i(\mathbf{w}^\top \mathbf{x}_i + b) = 1.$$

Les hyperplans « frontières » de la marge deviennent  $\mathbf{w}^\top \mathbf{x} + b = \pm 1$ .

**Proposition 2.1** (Largeur de la marge). *Sous la normalisation canonique, la largeur du couloir entre les deux hyperplans  $\mathbf{w}^\top \mathbf{x} + b = \pm 1$  vaut  $\frac{2}{\|\mathbf{w}\|}$ .*

*Démonstration.* Soit  $\mathbf{x}^-$  un point sur l'hyperplan  $\mathbf{w}^\top \mathbf{x} + b = -1$ . Déplaçons-nous perpendiculairement (le long de  $\mathbf{w}/\|\mathbf{w}\|$ ) jusqu'à l'autre hyperplan :  $\mathbf{x}^+ = \mathbf{x}^- + t \frac{\mathbf{w}}{\|\mathbf{w}\|}$ . Alors

$$\mathbf{w}^\top \mathbf{x}^+ + b = \mathbf{w}^\top \mathbf{x}^- + b + t \frac{\mathbf{w}^\top \mathbf{w}}{\|\mathbf{w}\|} = -1 + t \|\mathbf{w}\|.$$

On veut  $\mathbf{w}^\top \mathbf{x}^+ + b = +1$ , d'où  $-1 + t \|\mathbf{w}\| = 1$ , soit  $t = \frac{2}{\|\mathbf{w}\|}$ . Cette distance  $t$  est la largeur de la marge.  $\square$

### À retenir

Maximiser la marge  $\frac{2}{\|\mathbf{w}\|}$  revient à **minimiser**  $\frac{1}{2} \|\mathbf{w}\|^2$ . C'est l'objectif des SVM.

## 2.4 SVM linéaire à marge dure

Si les données sont *parfaitement* séparables :

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{sous} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 \quad \forall i.$$

## 2.5 SVM à marge souple

En pratique les données ne sont pas parfaitement séparables. On introduit des **variables de relâchement**  $\xi_i \geq 0$  qui autorisent des violations de la marge :

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i \quad \text{sous} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0. \quad (1)$$

### Le rôle de $C$

$C$  arbitre entre **marge large** (petit  $\|\mathbf{w}\|$ ) et **peu de violations** (petit  $\sum \xi_i$ ).  $C$  **grand** : on tolère peu d'erreurs  $\Rightarrow$  marge étroite, risque de surapprentissage.  $C$  **petit** : marge large, plus de violations tolérées  $\Rightarrow$  plus de régularisation. C'est exactement le  $C$  de la **LogisticRegression** de scikit-learn : un *inverse* de force de régularisation.

## 2.6 Équivalence avec la hinge loss

À  $(\mathbf{w}, b)$  fixés, le  $\xi_i$  optimal minimise  $C\xi_i$  sous  $\xi_i \geq 1 - y_i f(\mathbf{x}_i)$  et  $\xi_i \geq 0$ , donc

$$\xi_i^* = \max(0, 1 - y_i f(\mathbf{x}_i)).$$

En substituant, (1) devient un problème **sans contraintes** :

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i f(\mathbf{x}_i)). \quad (2)$$

On reconnaît la **perte charnière** (*hinge loss*)  $\ell(y, f) = \max(0, 1 - yf)$  plus une régularisation  $L_2$ .

### Lire la hinge loss

La hinge loss ne pénalise pas un point déjà bien classé *au-delà* de la marge ( $yf \geq 1$ , perte nulle). Dès que  $yf < 1$  (dans la marge ou mal classé), la pénalité croît linéairement. C'est ce « plateau à zéro » qui produit la parcimonie en vecteurs de support.

## 3 Dualité : dérivation complète

### 3.1 Le Lagrangien

On associe des multiplicateurs  $\alpha_i \geq 0$  aux contraintes de marge et  $\mu_i \geq 0$  aux contraintes  $\xi_i \geq 0$  :

$$\mathcal{L} = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_i \xi_i - \sum_i \alpha_i [y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1 + \xi_i] - \sum_i \mu_i \xi_i.$$

### 3.2 Conditions de stationnarité

On annule les dérivées par rapport aux variables primales :

$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = \mathbf{w} - \sum_i \alpha_i y_i \mathbf{x}_i = 0 \Rightarrow \boxed{\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i},$$

$$\frac{\partial \mathcal{L}}{\partial b} = -\sum_i \alpha_i y_i = 0 \Rightarrow \sum_i \alpha_i y_i = 0, \quad \frac{\partial \mathcal{L}}{\partial \xi_i} = C - \alpha_i - \mu_i = 0 \Rightarrow \alpha_i = C - \mu_i.$$

Comme  $\mu_i \geq 0$ , la dernière relation impose  $\alpha_i \leq C$ , d'où  $0 \leq \alpha_i \leq C$ .

### 3.3 Substitution : le problème dual

On réinjecte ces relations dans  $\mathcal{L}$ . D'abord  $\frac{1}{2} \|\mathbf{w}\|^2 = \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle$  et  $\sum_i \alpha_i y_i (\mathbf{w}^\top \mathbf{x}_i) = \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle$ . Ensuite les termes en  $\xi$  s'annulent :

$$C \sum_i \xi_i - \sum_i \alpha_i \xi_i - \sum_i \mu_i \xi_i = \sum_i \xi_i \underbrace{(C - \alpha_i - \mu_i)}_{=0} = 0,$$

et  $-b \sum_i \alpha_i y_i = 0$ . Il reste donc

$$\mathcal{L} = \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle - \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle + \sum_i \alpha_i.$$

On obtient le **problème dual** (à maximiser en  $\alpha$ ) :

$$\boxed{\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle \quad \text{sous} \quad 0 \leq \alpha_i \leq C, \sum_i \alpha_i y_i = 0.} \quad (3)$$

#### Pourquoi le dual est précieux

Le dual ne fait intervenir les données *que* par des **produits scalaires**  $\langle \mathbf{x}_i, \mathbf{x}_j \rangle$ . C'est exactement ce qui permettra le **kernel trick** : remplacer ces produits par un noyau  $K(\mathbf{x}_i, \mathbf{x}_j)$  pour travailler implicitement dans un espace de très grande dimension.

### 3.4 Fonction de décision et vecteurs de support

En remplaçant  $\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$  :

$$f(\mathbf{x}) = \sum_i \alpha_i y_i \langle \mathbf{x}_i, \mathbf{x} \rangle + b, \quad \hat{y} = \text{sign}(f(\mathbf{x})).$$

Les points tels que  $\alpha_i > 0$  sont les **vecteurs de support** (support vectors) : eux seuls déterminent  $f$ .

### 3.5 Conditions KKT : qui sont les vecteurs de support ?

Les conditions de complémentarité ( $\alpha_i[\dots] = 0$  et  $\mu_i \xi_i = 0$ ) classent chaque point :

| Valeur de $\alpha_i$ | Position                                                                | Rôle                             |
|----------------------|-------------------------------------------------------------------------|----------------------------------|
| $\alpha_i = 0$       | au-delà de la marge ( $y_i f(\mathbf{x}_i) > 1$ )                       | <i>pas</i> un vecteur de support |
| $0 < \alpha_i < C$   | exactement <i>sur</i> la marge ( $y_i f(\mathbf{x}_i) = 1, \xi_i = 0$ ) | SV « libre »                     |
| $\alpha_i = C$       | dans la marge ou mal classé ( $\xi_i > 0$ )                             | SV « borné »                     |

### Parcimonie

La plupart des points ont  $\alpha_i = 0$  : la solution ne dépend que d'une **petite fraction** des données (les vecteurs de support). C'est ce qui rend les SVM compacts et bien généralisants.

### 3.6 Récupération du biais $b$

Pour un vecteur de support « libre » ( $0 < \alpha_i < C$ , donc sur la marge  $y_i f(\mathbf{x}_i) = 1$ ), on a  $y_i(\mathbf{w}^\top \mathbf{x}_i + b) = 1$ , soit (en multipliant par  $y_i$  et  $y_i^2 = 1$ )

$$b = y_i - \sum_j \alpha_j y_j \langle \mathbf{x}_j, \mathbf{x}_i \rangle.$$

On moyenne sur tous les SV libres pour la stabilité numérique.

## 4 Noyaux (kernels)

### 4.1 Définition et kernel trick

Un **noyau** est une fonction  $K(\mathbf{x}, \mathbf{z}) = \langle \varphi(\mathbf{x}), \varphi(\mathbf{z}) \rangle$  qui calcule un produit scalaire dans l'espace de caractéristiques **sans évaluer  $\varphi$  explicitement**. Dans le dual (3), on remplace simplement

$$\langle \mathbf{x}_i, \mathbf{x}_j \rangle \longrightarrow K(\mathbf{x}_i, \mathbf{x}_j).$$

C'est le **kernel trick** : un séparateur linéaire dans l'espace de caractéristiques devient une frontière *non linéaire* dans l'espace d'origine.

### 4.2 Condition de Mercer

Un noyau est valide (c.-à-d. correspond à un vrai produit scalaire) si sa **matrice de Gram** est semi-définie positive :

$$\sum_{i,j} c_i c_j K(\mathbf{x}_i, \mathbf{x}_j) \geq 0 \quad \forall \{\mathbf{x}_i\}, \forall \{c_i\}.$$

### 4.3 Exemples

$$\begin{aligned} \text{Linéaire : } K(\mathbf{x}, \mathbf{z}) &= \mathbf{x}^\top \mathbf{z}, \\ \text{Polynômial : } K(\mathbf{x}, \mathbf{z}) &= (\gamma \mathbf{x}^\top \mathbf{z} + r)^p, \\ \text{RBF (gaussien) : } K(\mathbf{x}, \mathbf{z}) &= \exp(-\gamma \|\mathbf{x} - \mathbf{z}\|^2), \\ \text{Sigmoïde : } K(\mathbf{x}, \mathbf{z}) &= \tanh(\gamma \mathbf{x}^\top \mathbf{z} + r). \end{aligned}$$

### Le noyau RBF voit l'infini

Le noyau RBF correspond à un espace de caractéristiques de dimension **infinie** (développement en série de l'exponentielle). On ne pourrait jamais calculer  $\varphi(\mathbf{x})$  explicitement, mais  $K$  se calcule en  $O(d)$ . C'est toute la magie : une puissance de représentation infinie pour un coût fini. Le paramètre  $\gamma$  contrôle la « portée » :  $\gamma$  grand = influence très locale (frontières très flexibles, risque de surapprentissage).

## 5 Régression : Support Vector Regression (SVR)

### 5.1 Principe : le tube $\varepsilon$ -insensible

On cherche une fonction  $f$  qui reste à moins de  $\varepsilon$  de chaque cible :  $|y_i - f(\mathbf{x}_i)| \leq \varepsilon$ . Les erreurs **inférieures à  $\varepsilon$  ne sont pas pénalisées** : on construit un « tube » de demi-largeur  $\varepsilon$  autour de  $f$ , et seuls les points qui en sortent comptent.

### 5.2 Problème primal

On introduit deux jeux de variables de relâchement  $\xi_i, \xi_i^* \geq 0$  (dépassement au-dessus / en dessous du tube) :

$$\min_{\mathbf{w}, b, \xi, \xi^*} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_i (\xi_i + \xi_i^*) \quad \text{sous} \quad \begin{cases} y_i - \mathbf{w}^\top \mathbf{x}_i - b \leq \varepsilon + \xi_i, \\ \mathbf{w}^\top \mathbf{x}_i + b - y_i \leq \varepsilon + \xi_i^*. \end{cases}$$

La perte associée est la **perte  $\varepsilon$ -insensible** :  $\ell_\varepsilon(y, f) = \max(0, |y - f| - \varepsilon)$ .

### 5.3 Dual et fonction de régression

Les conditions de stationnarité donnent  $\mathbf{w} = \sum_i (\alpha_i - \alpha_i^*) \mathbf{x}_i$  et  $\sum_i (\alpha_i - \alpha_i^*) = 0$ . Le dual est

$$\max_{\alpha, \alpha^*} -\frac{1}{2} \sum_{i,j} (\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*) K(\mathbf{x}_i, \mathbf{x}_j) - \varepsilon \sum_i (\alpha_i + \alpha_i^*) + \sum_i y_i (\alpha_i - \alpha_i^*),$$

sous  $0 \leq \alpha_i, \alpha_i^* \leq C$ . La fonction de régression est

$$f(\mathbf{x}) = \sum_i (\alpha_i - \alpha_i^*) K(\mathbf{x}_i, \mathbf{x}) + b.$$

Les vecteurs de support sont les points *hors* du tube ( $\alpha_i > 0$  ou  $\alpha_i^* > 0$ ).

## 6 Limites des SVM

### Points faibles

- **Passage à l'échelle** : l'entraînement coûte typiquement entre  $O(m^2)$  et  $O(m^3) \Rightarrow$  mal adapté aux très grands jeux de données (on préfère alors le SVM linéaire ou la descente de gradient stochastique sur la hinge loss).
- **Réglage des hyperparamètres** :  $C$ , le noyau, et  $\gamma$  (RBF) demandent une recherche par validation croisée.
- **Pas de probabilités natives** :  $f(\mathbf{x})$  donne un score, pas une probabilité ; il faut un post-traitement (*Platt scaling*).
- **Sensibilité à l'échelle** : les variables doivent être standardisées (la marge dépend des distances).
- **Interprétabilité** : avec un noyau non linéaire, le modèle perd la lisibilité d'un séparateur linéaire.
- **Binaire par nature** : le multiclasse se traite par *un-contre-un* ou *un-contre-tous*.

## 7 Synthèse

La classification et la régression partagent la même forme finale :

$$f(\mathbf{x}) = \sum_i \beta_i K(\mathbf{x}_i, \mathbf{x}) + b, \quad \begin{cases} \beta_i = \alpha_i y_i & (\text{classification}), \\ \beta_i = \alpha_i - \alpha_i^* & (\text{régression}). \end{cases}$$

### À retenir

- Le SVM cherche le séparateur de **marge maximale** : maximiser  $\frac{2}{\|\mathbf{w}\|}$  = minimiser  $\frac{1}{2} \|\mathbf{w}\|^2$ .
- La **marge souple** ( $C \sum \xi_i$ ) équivaut à minimiser la **hinge loss** avec régularisation  $L_2$ .
- Le passage au **dual** ne laisse apparaître que des produits scalaires, ce qui autorise le **kernel trick** pour la non-linéarité.
- Les **conditions KKT** rendent la solution **parcimonieuse** : seuls les vecteurs de support comptent.
- Le **SVR** transpose l'idée à la régression via le tube  $\varepsilon$ -insensible.
- Forces : optimisation **convexe**, régularisation explicite, bonne généralisation. Limites : coût sur grands  $m$ , réglages, pas de probabilités natives.