

Les séries temporelles

Stationnarité, ACF/PACF, AR, MA, ARMA, ARIMA
et méthodologie de Box–Jenkins

5 juin 2026

Table des matières

1	Introduction	1
2	Décomposition classique	1
3	Stationnarité	2
3.1	Stationnarité stricte	2
3.2	Stationnarité faible (d'ordre 2)	2
3.3	Autocovariance et autocorrélation	2
3.4	Bruit blanc	2
4	L'opérateur retard (backshift)	2
5	Processus autorégressifs $AR(p)$	3
5.1	Définition	3
5.2	$AR(1)$: autocovariance (dérivation)	3
5.3	$AR(p)$: équations de Yule–Walker	3
6	Processus à moyenne mobile $MA(q)$	4
6.1	Définition et autocovariance	4
6.2	Inversibilité	4
7	Processus ARMA et ARIMA	4
7.1	$ARMA(p, q)$	4
7.2	$ARIMA(p, d, q)$: gérer la non-stationnarité	4
8	Estimation et identification	5
8.1	Estimation empirique	5
8.2	ACF, PACF et règle d'identification	5
8.3	Tests de significativité	5
9	Le théorème de Wold et la méthodologie de Box–Jenkins	6
10	Limites et extensions	6
11	Synthèse	7

1 Introduction

Une **série temporelle** est une suite d'observations collectées à intervalles réguliers : chômage mensuel (économie), cours boursiers quotidiens (finance), précipitations journalières (environnement), EEG toutes les quelques secondes (médecine). On note la suite doublement infinie de variables aléatoires

$$\dots, X_{-2}, X_{-1}, X_0, X_1, X_2, \dots \quad (X_t)_{t \in \mathbb{Z}}.$$

Les **objectifs** sont de décrire/résumer la série, d'ajuster un modèle de faible dimension, et de **prévoir**.

Ce qui change par rapport à l'apprentissage classique

Les observations ne sont **pas indépendantes** : X_t dépend de son passé. Cette **dépendance temporelle** (autocorrélation) est à la fois le défi et la ressource : c'est elle qui permet de prévoir, mais elle invalide les hypothèses i.i.d. habituelles.

2 Décomposition classique

Une description simple décompose la série en quatre composantes :

- **Tendance** T_t — mouvement de long terme de la moyenne ;
- **Saisonnalité** S_t — fluctuations cycliques liées au calendrier (période fixe) ;
- **Cycles** C_t — autres fluctuations cycliques (p. ex. cycles économiques) ;
- **Résidus** ε_t — fluctuations aléatoires restantes.

On les combine de manière **additive** $X_t = T_t + S_t + C_t + \varepsilon_t$ ou **multiplicative** $X_t = T_t \cdot S_t \cdot C_t \cdot \varepsilon_t$.

Du multiplicatif à l'additif par le log

Une série multiplicative se ramène au cas additif par transformation logarithmique :

$$\log(X_t) = \log(T_t S_t \varepsilon_t) = \log T_t + \log S_t + \log \varepsilon_t.$$

Le log linéarise aussi une croissance exponentielle et stabilise une variance qui croît avec le niveau.

3 Stationnarité

3.1 Stationnarité stricte

(X_t) est **strictement stationnaire** si, pour tout choix d'indices $t_1, \dots, t_k$ et tout décalage h ,

$$(X_{t_1}, \dots, X_{t_k}) \stackrel{\mathcal{D}}{=} (X_{t_1+h}, \dots, X_{t_k+h}).$$

Le comportement probabiliste *complet* ne dépend pas du temps, seulement des écarts entre instants.

3.2 Stationnarité faible (d'ordre 2)

(X_t) est **faiblement stationnaire** si :

$$(1) \mathbb{E}(X_t) = \mu \text{ (constante)}, \quad (2) \text{cov}(X_t, X_{t+k}) = \gamma_k \text{ (dépend de } k, \text{ pas de } t).$$

Pourquoi exiger la stationnarité ?

Pour estimer un modèle à partir d'une seule trajectoire, il faut que les propriétés statistiques soient **stables dans le temps** : sinon, le passé n'informe pas le futur. La stationnarité est l'hypothèse qui rend la prévision possible. La plupart des séries réelles ne le sont pas (tendance, saison) : on les **rend** stationnaires (différenciation, désaisonnalisation).

3.3 Autocovariance et autocorrélation

La suite $\{\gamma_k, k \in \mathbb{Z}\}$ est la **fonction d'autocovariance**, $\gamma_k = \text{cov}(X_t, X_{t+k})$. La **fonction d'autocorrélation** (ACF) est

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \text{corr}(X_t, X_{t+k}), \quad k \in \mathbb{Z}.$$

Propriétés : $\gamma_0 = \text{Var}(X_t) > 0$, symétrie $\gamma_k = \gamma_{-k}$, et $|\rho_k| \leq 1$.

Relations entre les deux notions

Un processus strictement stationnaire à moments d'ordre 2 finis est faiblement stationnaire. Réciproque *en général fausse, sauf* pour les processus **gaussiens** : pour eux, stationnarité faible $\Rightarrow$ stationnarité stricte (la loi normale est entièrement déterminée par sa moyenne et sa covariance).

3.4 Bruit blanc

Le **bruit blanc** (ε_t) est une suite de variables non corrélées, de moyenne nulle et de variance σ^2 :

$$\gamma_0 = \sigma^2, \quad \gamma_k = 0 \quad (k \neq 0).$$

C'est la « brique » élémentaire : un modèle est *adéquat* quand ses résidus ressemblent à un bruit blanc.

4 L'opérateur retard (backshift)

Définition 4.1 (Opérateur retard B). B décale la série d'un pas vers le passé : $BX_t = X_{t-1}$, et plus généralement $B^k X_t = X_{t-k}$.

Il permet d'écrire tous les modèles de manière compacte, via des **polynômes en B** :

$$\Phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p \quad (\text{partie AR}), \quad \Theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q \quad (\text{partie MA}).$$

Intuition

L'opérateur retard transforme des récurrences en algèbre de polynômes. Les conditions de stationnarité et d'inversibilité se liront alors comme des conditions sur les **racines** de ces polynômes.

5 Processus autorégressifs AR(p)

5.1 Définition

$$X_t = \sum_{r=1}^p \phi_r X_{t-r} + \varepsilon_t, \quad \text{soit} \quad \Phi(B)X_t = \varepsilon_t,$$

où (ε_t) est un bruit blanc. « La valeur actuelle est une combinaison linéaire de son propre passé, plus un choc aléatoire. »

5.2 AR(1) : autocovariance (dérivation)

Soit $X_t = \phi_1 X_{t-1} + \varepsilon_t$, $|\phi_1| < 1$. Par substitutions successives, on obtient la forme MA(∞) :

$$X_t = \varepsilon_t + \phi_1 \varepsilon_{t-1} + \phi_1^2 \varepsilon_{t-2} + \dots = \sum_{r=0}^{\infty} \phi_1^r \varepsilon_{t-r}.$$

Donc $\mathbb{E}(X_t) = 0$ et, par indépendance des ε :

$$\gamma_0 = \mathbb{E}\left(\sum_r \phi_1^r \varepsilon_{t-r}\right)^2 = (1 + \phi_1^2 + \phi_1^4 + \dots) \sigma^2 = \frac{\sigma^2}{1 - \phi_1^2}, \quad \gamma_k = \frac{\sigma^2 \phi_1^{|k|}}{1 - \phi_1^2}.$$

Méthode plus rapide. On multiplie $X_t = \phi_1 X_{t-1} + \varepsilon_t$ par X_{t-k} et on prend l'espérance ; comme $\mathbb{E}(\varepsilon_t X_{t-k}) = 0$ pour $k \geq 1$:

$$\gamma_k = \phi_1 \gamma_{k-1} \Rightarrow \gamma_k = \phi_1^k \gamma_0, \quad \text{d'où} \quad \rho_k = \phi_1^{|k|}.$$

L'ACF décroît **géométriquement**.

5.3 AR(p) : équations de Yule-Walker

En multipliant la définition par X_{t-k} , en prenant l'espérance et en divisant par γ_0 , on obtient les **équations de Yule-Walker** :

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} + \dots + \phi_p \rho_{k-p}, \quad k \geq 1. \quad (1)$$

Ce sont des récurrences linéaires dont la solution générale est $\rho_k = C_1 \omega_1^{|k|} + \dots + C_p \omega_p^{|k|}$, où les ω_i sont les racines de

$$\omega^p - \phi_1 \omega^{p-1} - \dots - \phi_p = 0.$$

Condition de stationnarité

On exige $\gamma_k \rightarrow 0$ quand $k \rightarrow \infty$, ce qui impose que toutes les racines soient **à l'intérieur du cercle unité**, $|\omega_i| < 1$ (de façon équivalente : les racines de $\Phi(B) = 0$ sont *hors* du cercle unité). L'ACF d'un AR décroît donc toujours (géométriquement ou en sinusoïde amortie).

6 Processus à moyenne mobile MA(q)

6.1 Définition et autocovariance

$$X_t = \sum_{s=0}^q \theta_s \varepsilon_{t-s} \quad (\theta_0 = 1), \quad \text{soit} \quad X_t = \Theta(B) \varepsilon_t.$$

Ce processus est **toujours stationnaire** (combinaison finie de bruit blanc), et son autocovariance s'annule au-delà de q :

$$\gamma_k = \begin{cases} \sigma^2 \sum_{s=0}^{q-|k|} \theta_s \theta_{s+|k|}, & |k| \leq q, \\ 0, & |k| > q. \end{cases}$$

La signature du MA

L'ACF d'un MA(q) est **nulle après le retard q** : c'est un « couperet ». C'est le critère d'identification (section 8).

6.2 Inversibilité

Deux MA peuvent partager la même ACF. Par exemple $X_t = \varepsilon_t + \theta\varepsilon_{t-1}$ et $X_t = \varepsilon_t + \frac{1}{\theta}\varepsilon_{t-1}$ ont tous deux $\rho_1 = \frac{\theta}{1+\theta^2}$. Pour lever l'ambiguïté, on impose l'**inversibilité** : le MA admet une représentation AR(∞),

$$\varepsilon_t = X_t - \theta X_{t-1} + \theta^2 X_{t-2} - \dots,$$

valable seulement si $|\theta| < 1$ (plus généralement : racines de $\Theta(B) = 0$ hors du cercle unité). **Deux processus inversibles distincts ne peuvent pas avoir la même ACF.**

7 Processus ARMA et ARIMA

7.1 ARMA(p, q)

On combine les deux mécanismes :

$$X_t - \sum_{r=1}^p \phi_r X_{t-r} = \sum_{s=0}^q \theta_s \varepsilon_{t-s}, \quad \text{soit} \quad \boxed{\Phi(B)X_t = \Theta(B)\varepsilon_t.}$$

Stationnaire pour des paramètres appropriés (racines de Φ hors du cercle unité).

Exemple 7.1 (Un modèle d'état donne un ARMA(1,1)). Soit le modèle à état caché $X_t = \phi X_{t-1} + \varepsilon_t$ (AR(1) non observé) et observation $Y_t = X_t + \eta_t$, avec $(\varepsilon_t), (\eta_t)$ bruits blancs indépendants. Posons $\xi_t = Y_t - \phi Y_{t-1}$:

$$\xi_t = (X_t - \phi X_{t-1}) + (\eta_t - \phi \eta_{t-1}) = \varepsilon_t + \eta_t - \phi \eta_{t-1}.$$

(ξ_t) est stationnaire avec $\text{cov}(\xi_t, \xi_{t+k}) = 0$ pour $k \geq 2$: c'est un MA(1). Donc (Y_t) est un **ARMA(1,1)**. (Un bruit d'observation transforme un AR en ARMA.)

7.2 ARIMA(p, d, q) : gérer la non-stationnarité

Si (Y_t) n'est pas stationnaire (tendance), on le **différencie**. Avec $\nabla = 1 - B$:

$$\nabla Y_t = Y_t - Y_{t-1}, \quad \nabla^2 Y_t = Y_t - 2Y_{t-1} + Y_{t-2}, \dots$$

(Y_t) est **ARIMA(p, d, q)** si $X_t = \nabla^d Y_t$ est un ARMA(p, q) stationnaire :

$$\Phi(B)(1-B)^d Y_t = \Theta(B)\varepsilon_t.$$

Intuition

d est le nombre de différenciations nécessaires pour « aplatir » la tendance. Différencier une fois élimine une tendance linéaire, deux fois une tendance quadratique. (La saisonnalité se traite par différenciation saisonnière $\Rightarrow$ modèles SARIMA.)

8 Estimation et identification

8.1 Estimation empirique

À partir d'observations $(X_1, \dots, X_T)$:

$$\bar{X} = \frac{1}{T} \sum_{t=1}^T X_t, \quad \hat{\gamma}_k = \frac{1}{T} \sum_{t=k+1}^T (X_t - \bar{X})(X_{t-k} - \bar{X}), \quad \hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0}.$$

Le graphe de $\hat{\rho}_k$ en fonction de k est le **corrélogramme**.

Pourquoi diviser par T et non $T - k$?

Diviser par T (et non par le nombre réel de termes $T - k$) garantit que la suite estimée $\{\hat{\gamma}_k\}$ est **semi-définie positive** (une vraie fonction d'autocovariance) et réduit souvent l'erreur quadratique de $\hat{\rho}_k$.

8.2 ACF, PACF et règle d'identification

La **PACF** (autocorrélation partielle) $\phi_{k,k}$ mesure la corrélation entre X_t et X_{t+k} après élimination de l'effet des retards intermédiaires $X_{t+1}, \dots, X_{t+k-1}$:

$$\phi_{k,k} = \text{corr}(X_{t+k} - \hat{X}_{t+k}, X_t - \hat{X}_t),$$

où $\hat{X}$ désigne la projection linéaire sur les retards intermédiaires (calculée par l'algorithme de **Levinson-Durbin**). Elle mesure donc l'effet **direct** du retard k , hors effets indirects.

Le tableau d'identification

Modèle	ACF	PACF
AR(p)	décroît (géom./sinusoïde)	s'annule après p
MA(q)	s'annule après q	décroît
ARMA(p, q)	décroît	décroît

Mémo : l'ACF repère l'ordre du MA, la PACF repère l'ordre de l'AR.

8.3 Tests de significativité

Les ACF/PACF empiriques sont approximativement normales, d'écart-type $\approx 1/\sqrt{T}$. On considère $\hat{\rho}_k$ (ou $\hat{\phi}_{k,k}$) comme négligeable s'il tombe dans la bande

$$\left[-\frac{2}{\sqrt{T}}, \frac{2}{\sqrt{T}} \right].$$

Le test global de **bruit blanc** (Box-Pierce / Ljung-Box) repose sur

$$Q'_m = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{T-k} \sim \chi_{m-p-q}^2 \quad (\text{sous } H_0).$$

Un grand Q'_m rejette l'hypothèse de bruit blanc des résidus (modèle insuffisant).

9 Le théorème de Wold et la méthodologie de Box-Jenkins

Théorème 9.1 (Décomposition de Wold, 1938). *Tout processus stationnaire d'ordre 2 **purement non déterministe** s'écrit comme un MA(∞) d'innovations non corrélées :*

$$X_t = \mu + \sum_{s=0}^{\infty} \theta_s Z_{t-s}, \quad (Z_t) \text{ non corrélées.}$$

Intuition

Ce théorème justifie toute l'approche : *n'importe quel* processus stationnaire raisonnable peut s'approcher par un MA (donc par un ARMA, qui est un MA(∞) « résumé » par un ratio de polynômes $\Theta(B)/\Phi(B)$). Les ARMA sont des approximations parcimonieuses de cette représentation universelle.

Méthodologie de Box–Jenkins

1. **Stationnariser** : transformer (log), différencier (d), désaisonnaliser jusqu'à obtenir une série stationnaire.
2. **Identifier** (p, q) : lire l'ACF et la PACF (tableau ci-dessus).
3. **Estimer** les paramètres (maximum de vraisemblance, moindres carrés, Yule–Walker).
4. **Diagnostiquer** : vérifier que les résidus sont un bruit blanc (Ljung–Box, ACF des résidus). Comparer les modèles par **AIC/BIC**.
5. **Prévoir** et calculer des intervalles de prédiction.

10 Limites et extensions

Ce que les modèles ARIMA ne capturent pas

- **Linéarité** : AR/MA/ARMA sont **linéaires** ; ils modélisent mal les dynamiques non linéaires.
- **Stationnarité requise** : il faut différencier/transformer ; le choix de d et des ordres reste délicat.
- **Variance constante** : ils supposent une variance fixe, alors que les séries financières ont une **volatilité variable** (clusters de volatilité).
- **Horizon** : les prévisions ARIMA convergent vite vers la moyenne ; peu utiles à long terme.
- **Multivarié** : une seule série à la fois (sinon VAR).

Extensions classiques

- **SARIMA** : ARIMA avec composante saisonnière (différenciation et termes saisonniers).
- **ARCH / GARCH** : modélisent la **volatilité** conditionnelle (variance qui dépend du passé) — incontournables en finance.
- **VAR / VARMA** : versions **multivariées** (plusieurs séries qui s'influencent).
- **Modèles à espace d'état / filtre de Kalman** : cadre général pour états cachés et observations bruitées.
- **Approches modernes** : Prophet, modèles d'apprentissage automatique (gradient boosting sur features temporelles) et **réseaux de neurones** (LSTM, Transformers) pour les dépendances longues et non linéaires.

11 Synthèse

À retenir

- Une série temporelle est une suite **dépendante** ; la **stationnarité** (au moins faible) est l'hypothèse clé pour la modéliser et la prévoir.
- L'**opérateur retard** B écrit tout via des polynômes : AR $\Phi(B)X_t = \varepsilon_t$, MA $X_t = \Theta(B)\varepsilon_t$, ARMA $\Phi(B)X_t = \Theta(B)\varepsilon_t$, ARIMA $\Phi(B)(1 - B)^d Y_t = \Theta(B)\varepsilon_t$.
- **Stationnarité** (AR) et **inversibilité** (MA) se lisent sur les racines des polynômes.
- **Identification** : ACF s'annule après q pour un MA, PACF s'annule après p pour un AR ; bande de significativité $\pm 2/\sqrt{T}$; test de Ljung–Box sur les résidus.
- **Box–Jenkins** : stationnariser $\rightarrow$ identifier $\rightarrow$ estimer $\rightarrow$ diagnostiquer $\rightarrow$ prévoir.
- **Limites** : linéarité, variance constante, court terme $\Rightarrow$ extensions SARIMA, GARCH, espace d'état, modèles ML/profonds.