Time Série

1 Modèles pour les séries temporelles

1.1 Données de séries temporelles

Une série temporelle est un ensemble de statistiques, généralement collectées à intervalles réguliers. Les données de séries temporelles apparaissent naturellement dans de nombreux domaines d'application :

— **Économie** — par exemple, données mensuelles sur le chômage, les admissions hospitalières, etc.

— **Finance** — par exemple, taux de change quotidiens, cours d'une action, etc.

— **Environnement** — par exemple, précipitations journalières, mesures de la qualité de l'air.

— **Médecine** — par exemple, activité des ondes cérébrales (ECG/EEG) toutes les 2 à 8 secondes.

Les méthodes d'analyse des séries temporelles sont antérieures à celles des processus stochastiques généraux et des chaînes de Markov. Les objectifs de l'analyse des séries temporelles sont de décrire et résumer les données, d'ajuster des modèles de faible dimension et d'effectuer des prévisions.

Nous écrivons notre série d'observations réelles comme $\ldots, X_{-2}, X_{-1}, X_0, X_1, X_2, \ldots$, une suite doublement infinie de variables aléatoires réelles indexées par $\mathbb{Z}$.

1.2 Tendance, saisonnalité, cycles et résidus

Une méthode simple pour décrire une série est la décomposition classique. L'idée est que la série peut être décomposée en quatre composantes :

— **Tendance** (T_t) — mouvements de long terme de la moyenne ;

— **Effets saisonniers** (S_t) — fluctuations cycliques liées au calendrier ;

— **Cycles** (C_t) — autres fluctuations cycliques (par exemple, les cycles économiques) ;

— **Résidus** (ε_t) — autres fluctuations aléatoires ou systématiques.

L'idée est de créer des modèles séparés pour ces quatre composantes, puis de les combiner, soit de manière additive :

$$X_t = T_t + S_t + C_t + \varepsilon_t \text{ ou } X_t = T_t + S_t + \varepsilon_t$$

soit de manière multiplicative :

$$X_t = T_t \cdot S_t \cdot C_t \cdot \varepsilon_t \text{ ou } X_t = T_t \cdot S_t \cdot \varepsilon_t$$

Si nous rencontrons une série temporelle dont le comportement est celui d'une série multiplicative, nous pouvons toujours nous ramener au cas additif grâce à une transformation logarithmique. Cette transformation permet d'établir des relations linéaires, plus simples à analyser et à modéliser.

Rappel :

$$\log(X_t) = \log\big(T_t S_t \varepsilon_t\big) = \log(T_t) + \log(S_t) + \log(\varepsilon_t).$$

Après avoir effectué la transformation logarithmique et l'analyse correspondante, on utilise la fonction exponentielle afin de retrouver la série originale :

$$\exp\big(\log(X_t)\big) = X_t.$$

1.3 Processus stationnaires

Soit $\{X_t,\ t \in \mathbb{Z}\}$ une série temporelle.

1. Stationnarité forte (ou stricte)

Le processus $\{X_t\}$ est dit *strictement stationnaire* si

$$(X_{t_1}, \ldots, X_{t_k}) \overset{D}{=} (X_{t_1+h}, \ldots, X_{t_k+h})$$

pour tout

— ensemble d'indice $t_1, \ldots, t_k$

— entier h

— tout $k \geq 1$

Cela signifie que **le comportement probabiliste complet du processus ne dépend pas du temps**, seulement des écarts entre les instants.

2. Stationnarité faible (ou d'ordre 2)

Le processus $\{X_t\}$ est dit *faiblement stationnaire* si :

1. $\mathbb{E}(X_t) = \mu$, où μ est une constante,
2. $\mathrm{cov}(X_t, X_{t+k}) = \gamma_k$, ne dépendant que du retard k ,indépendence du temps t(La covariance ne dépend **pas de** t, mais seulement du **lag** k.)

3. Fonction d'autocovariance

La suite

$$\{\gamma_k,\ k \in \mathbb{Z}\}$$

est appelée *fonction d'autocovariance*, où

$$\gamma_{(t+k)-t} = \gamma_k = \mathrm{cov}(X_t, X_{t+k}).$$

4. Fonction d'autocorrélation (ACF)

On définit la fonction d'autocorrélation par

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \mathrm{corr}(X_t, X_{t+k}), \quad k \in \mathbb{Z}.$$

Remarques

1. Un processus strictement stationnaire admettant des moments d'ordre 2 finis est faiblement stationnaire.
2. Si le processus est gaussien, c'est-à-dire si

$$(X_{t_1}, \ldots, X_{t_k}) \sim \mathcal{N},$$

   alors la stationnarité faible implique la stationnarité forte.
3. $\gamma_0 = \mathrm{var}(X_t) > 0$, en supposant que X_t n'est pas déterministe.
4. Par symétrie,

$$\gamma_k = \gamma_{-k}, \quad \forall k \in \mathbb{Z}.$$

1.4 Processus autorégressifs

Le processus autorégressif d'ordre p est noté AR(p) et défini par

$$X_t = \sum_{r=1}^{p} \phi_r X_{t-r} + \varepsilon_t \tag{1.1}$$

où $\phi_1, \ldots, \phi_p$ sont des constantes fixes et $\{\varepsilon_t\}$ est une suite de variables aléatoires indépendantes (ou non corrélées), de moyenne nulle et de variance σ^2.

Le processus AR(1) est défini par

$$X_t = \phi_1 X_{t-1} + \varepsilon_t. \tag{1.2}$$

Pour déterminer sa fonction d'autocovariance, on effectue des substitutions successives :

$$X_t = \varepsilon_t + \phi_1(\varepsilon_{t-1} + \phi_1(\varepsilon_{t-2} + \cdots)) = \varepsilon_t + \phi_1\varepsilon_{t-1} + \phi_1^2\varepsilon_{t-2} + \cdots$$

Le fait que $\{X_t\}$ soit stationnaire au second ordre découle de l'observation que $E(X_t) = 0$ et que la fonction d'autocovariance peut être calculée comme suit :

$$\gamma_0 = E\left(\varepsilon_t + \phi_1\varepsilon_{t-1} + \phi_1^2\varepsilon_{t-2} + \cdots\right)^2 = (1 + \phi_1^2 + \phi_1^4 + \cdots)\sigma^2 = \frac{\sigma^2}{1-\phi_1^2},$$

$$\gamma_k = E\left(\sum_{r=0}^{\infty} \phi_1^r \varepsilon_{t-r} \sum_{s=0}^{\infty} \phi_1^s \varepsilon_{t+k-s}\right) = \frac{\sigma^2\phi_1^k}{1-\phi_1^2}.$$

Il existe une méthode plus simple pour obtenir ces résultats. On multiplie l'équation (1.2) par X_{t-k} et on prend l'espérance :

$$E(X_t X_{t-k}) = E(\phi_1 X_{t-1} X_{t-k}) + E(\varepsilon_t X_{t-k}).$$

Ainsi,

$$\gamma_k = \phi_1\gamma_{k-1}, \quad k = 1, 2, \ldots$$

De même, en élevant (1.2) au carré et en prenant l'espérance :

$$E(X_t^2) = \phi_1^2 E(X_{t-1}^2) + 2\phi_1 E(X_{t-1}\varepsilon_t) + E(\varepsilon_t^2) = \phi_1^2 E(X_{t-1}^2) + \sigma^2,$$

d'où

$$\gamma_0 = \frac{\sigma^2}{1-\phi_1^2}.$$

Plus généralement, le processus AR(p) est défini par

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + \varepsilon_t. \tag{1.3}$$

La fonction d'autocorrélation s'obtient en multipliant (1.3) par X_{t-k}, en prenant l'espérance et en divisant par γ_0, ce qui conduit aux équations de Yule–Walker :

$$\rho_k = \phi_1\rho_{k-1} + \phi_2\rho_{k-2} + \cdots + \phi_p\rho_{k-p}, \quad k = 1, 2, \ldots$$

Ce sont des relations de récurrence linéaires, dont la solution générale est de la forme

$$\rho_k = C_1\omega_1^{|k|} + \cdots + C_p\omega_p^{|k|},$$

où $\omega_1, \ldots, \omega_p$ sont les racines de

$$\omega^p - \phi_1\omega^{p-1} - \phi_2\omega^{p-2} - \cdots - \phi_p = 0,$$

et où $C_1, \ldots, C_p$ sont déterminées par $\rho_0 = 1$ et les équations pour $k = 1, \ldots, p-1$.

Il est naturel d'exiger que $\gamma_k \to 0$ lorsque $k \to \infty$, ce qui impose que les racines soient à l'intérieur du cercle unité, c'est-à-dire $|\omega_i| < 1$. Cela impose des restrictions sur les valeurs possibles de $\phi_1, \ldots, \phi_p$.

1.5 Processus à moyenne mobile

Le processus à moyenne mobile d'ordre q est noté MA(q) et défini par

$$X_t = \sum_{s=0}^{q} \theta_s \varepsilon_{t-s}, \tag{1.4}$$

où $\theta_1, \ldots, \theta_q$ sont des constantes fixes, $\theta_0 = 1$, et $\{\varepsilon_t\}$ est une suite de variables aléatoires indépendantes (ou non corrélées), de moyenne nulle et de variance σ^2.

Il est clair, d'après la définition, que ce processus est stationnaire au second ordre et que

$$\gamma_k = \begin{cases} 0, & |k| > q, \\ \sigma^2 \sum_{s=0}^{q-|k|} \theta_s \theta_{s+k}, & |k| \leq q. \end{cases}$$

On remarque que deux processus à moyenne mobile peuvent avoir la même fonction d'autocorrélation. Par exemple,

$$X_t = \varepsilon_t + \theta \varepsilon_{t-1} \quad \text{et} \quad X_t = \varepsilon_t + \frac{1}{\theta} \varepsilon_{t-1}$$

ont tous deux

$$\rho_1 = \frac{\theta}{1+\theta^2}, \quad \rho_k = 0 \text{ pour } |k| > 1.$$

Cependant, le premier conduit à

$$\varepsilon_t = X_t - \theta \varepsilon_{t-1} = X_t - \theta(X_{t-1} - \theta \varepsilon_{t-2}) = X_t - \theta X_{t-1} + \theta^2 X_{t-2} - \cdots$$

ce qui n'est valable que pour $|\theta| < 1$. On parle alors de processus inversible. Deux processus inversibles distincts ne peuvent pas avoir la même fonction d'autocorrélation.

1.6 Bruit blanc

La suite $\{\varepsilon_t\}$, constituée de variables aléatoires indépendantes (ou non corrélées), de moyenne nulle et de variance σ^2, est appelée bruit blanc. C'est une série stationnaire au second ordre vérifiant

$$\gamma_0 = \sigma^2 \quad \text{et} \quad \gamma_k = 0, \ k \neq 0.$$

2 Modèles de processus stationnaires

2.1 Processus purement indéterministes

Soit $\{X_t\}$ un processus stationnaire au second ordre, de moyenne nulle. Sa fonction d'autocovariance est définie par

$$\gamma_k = E(X_t X_{t+k}) = \mathrm{cov}(X_t, X_{t+k}), \quad k \in \mathbb{Z}.$$

1. Comme $\{X_t\}$ est stationnaire, γ_k ne dépend pas de t.
2. Un processus est dit *purement indéterministe* si la régression de X_t sur $X_{t-q}, X_{t-q-1}, \ldots$ a un pouvoir explicatif qui tend vers zéro lorsque $q \to \infty$. Autrement dit, la variance résiduelle tend vers $\mathrm{Var}(X_t)$.

Un théorème fondamental dû à Wold (1938) affirme que tout processus stationnaire au second ordre purement indéterministe $\{X_t\}$ peut s'écrire sous la forme

$$X_t = \mu + \theta_0 Z_t + \theta_1 Z_{t-1} + \theta_2 Z_{t-2} + \cdots,$$

où $\{Z_t\}$ est une suite de variables aléatoires non corrélées.

Processus gaussien. Un processus est dit gaussien si, pour tout ensemble $t_1, \ldots, t_n$, le vecteur $(X_{t_1}, \ldots, X_{t_n})$ suit une loi normale multivariée. Deux processus gaussiens distincts ne peuvent pas avoir la même fonction d'autocovariance.

2.2 Processus ARMA

Un processus autorégressif à moyenne mobile, noté ARMA(p, q), est défini par

$$X_t - \sum_{r=1}^{p} \phi_r X_{t-r} = \sum_{s=0}^{q} \theta_s \varepsilon_{t-s},$$

où $\{\varepsilon_t\}$ est un bruit blanc. Ce processus est stationnaire pour des choix appropriés des paramètres ϕ et θ.

Exemple 2.1 Considérons le modèle d'état

$$X_t = \phi X_{t-1} + \varepsilon_t,$$

$$Y_t = X_t + \eta_t,$$

où $\{X_t\}$ est non observé, $\{Y_t\}$ est observé, et $\{\varepsilon_t\}$, $\{\eta_t\}$ sont deux suites de bruits blancs indépendantes. Le processus $\{X_t\}$ est AR(1).

Définissons

$$\xi_t = Y_t - \phi Y_{t-1}.$$

Alors

$$\xi_t = (X_t + \eta_t) - \phi(X_{t-1} + \eta_{t-1}) = (X_t - \phi X_{t-1}) + (\eta_t - \phi\eta_{t-1}) = \varepsilon_t + \eta_t - \phi\eta_{t-1}.$$

Le processus $\{\xi_t\}$ est stationnaire et vérifie $\mathrm{cov}(\xi_t, \xi_{t+k}) = 0$ pour $k \geq 2$. Il peut donc être modélisé comme un MA(1), et $\{Y_t\}$ est un processus ARMA(1,1).

2.3 Processus ARIMA

Si le processus original $\{Y_t\}$ n'est pas stationnaire, on peut considérer les différences d'ordre 1 :

$$X_t = \nabla Y_t = Y_t - Y_{t-1},$$

ou d'ordre 2 :

$$X_t = \nabla^2 Y_t = Y_t - 2Y_{t-1} + Y_{t-2},$$

et ainsi de suite.

Si le processus différencié est stationnaire, on peut alors lui ajuster un modèle ARMA.

Le processus $\{Y_t\}$ est dit *autorégressif intégré à moyenne mobile*, noté ARIMA(p, d, q), si

$$X_t = \nabla^d Y_t$$

est un processus ARMA(p, q).

Les modèles AR, MA, ARMA et ARIMA permettent de modéliser de nombreuses séries temporelles. Un outil essentiel pour l'identification est l'estimation de la fonction d'autocovariance.

2.4 Estimation de la fonction d'autocovariance

Soient $(X_1, \ldots, X_T)$ des observations issues d'une série temporelle stationnaire.

On estime :

— la moyenne par

$$\bar{X} = \frac{1}{T} \sum_{t=1}^{T} X_t,$$

— l'autocovariance par

$$\hat{\gamma}_k = \frac{1}{T} \sum_{t=k+1}^{T} (X_t - \bar{X})(X_{t-k} - \bar{X}),$$

— l'autocorrélation par

$$\hat{\rho}_k = \frac{\hat{\gamma}_k}{\hat{\gamma}_0}.$$

Le graphe de $\hat{\rho}_k$ en fonction de k est appelé *corrélogramme*. Si la moyenne μ est connue et nulle, on peut estimer

$$\hat{\gamma}_k = \frac{1}{T} \sum_{t=k+1}^{T} X_t X_{t-k}.$$

Le fait de diviser par T plutôt que par $(T-k)$:

— garantit que $\{\hat{\gamma}_k\}$ est définie positive,

— peut réduire l'erreur quadratique moyenne de $\hat{\rho}_k$.

2.5 Identification d'un processus MA(q)

Pour un processus MA(q),

$$\rho_k = 0 \quad \text{pour } |k| > q.$$

Ainsi, un diagnostic de MA(q) est que les autocorrélations empiriques deviennent proches de zéro au-delà d'un certain retard.

2.6 Identification d'un processus AR(p)

Pour un processus AR(p), les autocorrélations décroissent de façon exponentielle. Les coefficients sont estimés par moindres carrés, ce qui conduit à des équations proches des équations de Yule–Walker :

$$\hat{\gamma}_j = \sum_{\ell=1}^{k} \hat{\phi}_{\ell,k} \hat{\gamma}_{|j-\ell|}, \quad j = 1, \ldots, k.$$

Ces équations sont résolues par l'algorithme de Levinson–Durbin. Le coefficient $\hat{\phi}_{k,k}$ est appelé *autocorrélation partielle empirique* (PACF).

Si le processus est réellement AR(p), alors

$$\phi_{k,k} = 0 \quad \text{pour } k > p.$$

2.7 Lois de l'ACF et de la PACF

Les ACF et PACF empiriques sont approximativement normales, centrées sur leurs valeurs théoriques, avec un écart-type proche de $1/\sqrt{T}$.

Une règle pratique consiste à considérer $\hat{\rho}_k$ (ou $\hat{\phi}_{k,k}$) comme négligeable s'il appartient à l'intervalle

$$\left[-\frac{2}{\sqrt{T}}, \frac{2}{\sqrt{T}} \right].$$

Un test global du bruit blanc (test de Box–Pierce ou Ljung–Box) repose sur la statistique

$$Q'_m = T(T+2) \sum_{k=1}^{m} \frac{\hat{r}_k^2}{T-k} \sim \chi^2_m.$$

Si le vrai modèle est ARMA(p, q), la puissance du test est maximale lorsque $m \approx p + q$.

A Autocorrélation partielle (PACF)

Soit $\{z_t\}_{t\in\mathbb{Z}}$ une série temporelle stationnaire au sens faible, de moyenne nulle.

L'**autocorrélation partielle au retard** k, notée $\phi_{k,k}$, est définie comme la corrélation entre z_t et z_{t+k} après élimination de la dépendance linéaire de ces deux variables vis-à-vis des observations intermédiaires

$$z_{t+1}, z_{t+2}, \ldots, z_{t+k-1}.$$

Autrement dit, $\phi_{k,k}$ mesure la part de corrélation entre z_t et z_{t+k} qui n'est pas expliquée par les retards 1 à $k-1$ inclus.

Cas $k = 1$

Pour $k = 1$, il n'existe pas de variables intermédiaires à éliminer. L'autocorrélation partielle coïncide donc avec l'autocorrélation simple :

$$\phi_{1,1} = \mathrm{corr}(z_{t+1}, z_t).$$

Cas général $k \geq 2$

Pour $k \geq 2$, l'autocorrélation partielle est définie comme la corrélation entre les résidus obtenus après projection linéaire :

$$\phi_{k,k} = \mathrm{corr}\left(z_{t+k} - \hat{z}_{t+k},\ z_t - \hat{z}_t\right),$$

où :

— $\hat{z}_{t+k}$ est la projection linéaire de z_{t+k} sur l'espace engendré par

$$\{z_{t+1}, z_{t+2}, \ldots, z_{t+k-1}\},$$

— $\hat{z}_t$ est la projection linéaire de z_t sur ce même espace,

— les coefficients de projection sont choisis de façon à minimiser l'erreur quadratique moyenne.

Forme explicite des projections (processus stationnaire)

Lorsque le processus $\{z_t\}$ est stationnaire, les coefficients des projections sont identiques, mais apparaissent dans l'ordre inverse. On peut alors écrire :

$$\hat{z}_{t+k} = \beta_1 z_{t+k-1} + \beta_2 z_{t+k-2} + \cdots + \beta_{k-1} z_{t+1},$$

et

$$\hat{z}_t = \beta_1 z_{t+1} + \beta_2 z_{t+2} + \cdots + \beta_{k-1} z_{t+k-1}.$$

Interprétation

L'autocorrélation partielle $\phi_{k,k}$ mesure l'effet linéaire *direct* du retard k sur la variable courante, indépendamment des effets indirects transmis par les retards intermédiaires. Cette propriété explique pourquoi, pour un processus autorégressif d'ordre p, on a :

$$\phi_{k,k} = 0 \quad \text{pour tout } k > p.$$